



# 인공지능수학

# 1. 거리(distance)


## ■ 인공지능에서는 이렇게 활용한다!

- ➡ 인공지능 분야에서는 과거의 데이터를 분석하여 최적의 모델을 만드는 학습 단계와, 그렇게 만들어진 모델을 사용해서 새로운 데이터에 대한 카테고리나 수치를 예측하는 추론 단계가 있습니다.
- ➡ 유클리드 거리는 인공지능 분야의 다양한 알고리즘에서 사용되는데, 그중 하나가 **k-NN(k-nearest neighbors algorithm)**이라는 분류 방법입니다. 이 방법은 소위 ‘교사가 있는 학습’, 즉 지도학습을 하기 때문에 미리 정답 데이터가 준비되어 있어야합니다.
- ➡ K-NN은 학습 단계에서 학습된 데이터를 벡터 공간상에 위치시킨 후, 추론 단계에서 새로운 데이터를 같은 공간에 배치합니다. 새 데이터가 어떤 카테고리에 속하는지 알기 위해서는 가까이 있는 k개의 정답 데이터를 보고 추론하게 되는데, 이때 사용하는 것이 바로 유클리드 거리입니다.

# 1. 거리(distance)

## ■ 인공지능에서는 이렇게 활용한다!


☞ 이해를 돕기 위해 예를 하나 들어보겠습니다. 학습 단계에서 다음 그림처럼 ‘페이지 수’와 ‘발행빈도’의 축으로 만들어진 공간이 있습니다. 여기에 학습 데이터를 위치시키고 카테고리를 매칭합니다. 추론 단계에서는 새 데이터(그림에서 ‘?’로 표시)를 페이지 수와 발행빈도에 맞게 위치시킨 후, 추론을 시작합니다. 만약  $k = 3$ 이라고 할 때, 새 데이터에서 가까운 두 개의 데이터가 ‘주간지’ 카테고리에 속하고, 1개의 데이터가 ‘광고잡지’ 카테고리에 분류되어 있다면 새로운 데이터는 ‘주간지’ 카테고리에 속한다고 추론하게 되는 것입니다.



# 1. 함수 혹은 수열

## ■ 인공지능에서는 이렇게 활용한다!

- ➡ 머신러닝 분야에서 주목받는 알고리즘의 하나인 ‘**신경망**’은 인간의 뇌 속에 있는 신경세포 ‘**뉴런**’과 그들의 연결 관계를 인공적으로 흉내 낸 것입니다.
- ➡ 뉴런에 입력되는 값은 여러 개의 ‘**입력값**’과 ‘**가중치( $\omega$ )**’의 곱을 모두 더한 다음, 여기에 상수를 더 추가한 것과 같습니다.
- ➡ 경우에 따라 다르겠지만 신경망에서는 이런 하나의 모델에서 이와 같은 덧셈이 수백만번 이루어지기도 합니다. 이런 계산식을 하나하나 쓰는 것은 사실상 불가능에 가깝기 때문에  $\sum$ 를 사용해서 표현합니다.



$$y = b + x_1 \cdot w_1 + x_2 \cdot w_2 + \cdots + x_n w_n$$


$$= \sum_{k=1}^n x_k w_k + b$$

신경망의 개요

# 2.1 미분 - 극한

## ■ 극한

⇒ 수열이나 함수값이 어떤 특정값에 한없이 가까워지는 것을 의미한다.



◆  $f(x) = \frac{x^2-1}{x-1}$

◆ lim 표현:

$$\lim_{x \rightarrow 1} \frac{x^2-1}{x-1} = \lim_{x \rightarrow 1} \frac{(x-1)(x+1)}{x-1} = \lim_{x \rightarrow 1} (x+1) = 2$$

⇒ 용어

- ◆ 수렴(convergent)  $x$ 의 값을 어떤 값  $a$ 에 최대한 가깝게 만들 때, 함수  $f(x)$ 의 값도 어떤 값  $\alpha$ 에 최대한 가까워지는 모양
- ◆ 극한값(limit, limiting value)  $\alpha$ 는 함수  $f(x)$ 에서  $x \rightarrow a$ 일 때의 극한값

⇒ 수식 표현

- ◆  $\lim_{x \rightarrow a} f(x) = \alpha$
- ◆  $f(x) \rightarrow \alpha \quad (x \rightarrow a)$

## 2.2 미분의 기초

### ■ 평균 속도

☞ 단위 시간당 얼마나 이동

$$\diamond v = \frac{\Delta x}{\Delta t}$$

이동 거리를 이동시간으로 나눔

### ■ 순간 속도


☞ 아주 짧은 구간의 속도

$$\diamond v = \lim_{\Delta t \rightarrow 0} \frac{\Delta x}{\Delta t} = \lim_{\Delta t \rightarrow 0} \frac{x(t+\Delta t) - x(t)}{\Delta t}$$

$\Delta x$  - 이동 거리의 변화량  
 $\Delta t$  - 이동 시간의 변화량

◆ 미분 표기

$$v = \frac{dx(t)}{dt}$$




이 구간의 거리는  $\Delta x = x(t + \Delta t) - x(t)$  라고 표현할 수 있습니다.

## 2.2 미분의 기초

### ■ 함수의 미분

#### ☞ 두 점을 지나는 직선


- ◆  $f(a) = \alpha a + \beta$
- ◆  $f(b) = \alpha b + \beta$
- ◆ 기울기  $\alpha = \frac{f(b)-f(a)}{b-a}$



#### ☞ 극한과 접선

- ◆ 미분 : 특정한 지점에서의 기울기 구하는 것

$$\frac{df(a)}{dx} = \lim_{\Delta x \rightarrow 0} \frac{\Delta f(a)}{\Delta x} = \lim_{h \rightarrow 0} \frac{f(a+h)-f(a)}{(a+h)-a} = \lim_{h \rightarrow 0} \frac{f(a+h)-f(a)}{h}$$



- ◆ 접선 : 점  $(a, f(a))$ 에서  $y = f(x)$  접하는 직선
- ◆ 미분계수 :  $x = a$  일 때의 평균변화율의 극한값  $\alpha$

## 2.2 미분의 기초

### ■ 함수의 미분

#### ⇒ 도함수

정의역의 모든  $x$ 에 대해 함수  $f(x)$ 의 미분계수를 대응시키는 새로운 함수를  $f(x)$ 의 도함수라고 한다.

$$\frac{df(x)}{dx} = \lim_{\Delta x \rightarrow 0} \frac{\Delta f(x)}{\Delta x} = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

#### ⇒ 표기:

- ◆ 1계 미분 :  $y'$ ,  $f'(x)$ ,  $\frac{dy}{dx}$ ,  $\frac{d}{dx}f(x)$
- ◆ 2계 미분 :  $y''$ ,  $f''(x)$ ,  $\frac{d^2}{dx^2}f(x)$



## 2.2 미분의 기초

### ■ 인공지능에서는 이렇게 활용한다!

- ⇒ 인공지능 분야에서는 함수의 값이 어느 지점에서 최소가 되는지를 알아내는 것이 중요합니다.
- ⇒ 예를 들면, **손실 함수(loss function)**는 정답과 예측값(측정값) 사이의 오차를 표현하는 함수인데, 인공지능 분야에서는 이 함수의 값을 최소로 만들기 위해 다양한 기법을 사용합니다.
- ⇒ 손실 함수를 미분하면 어떤 특정 지점에서 어느 정도의 기울기가 나오는지 알 수 있는데, 이러한 기울기의 절댓값이 작아지는 방향으로 그 지점을 옮기다 보면 손실 함수의 최솟값을 구할 수 있습니다. 이 방법을 **경사하강법 (gradient descent)** 이라 부릅니다.



## 2.3 상미분과 편미분

### ■ 상미분(ordinary derivative)

⇒ 변수 하나만 있는 함수의 미분

⇒ 주요 공식

$$\textcircled{1} \quad y = x^r \text{ 일 때 } \frac{dy}{dx} = rx^{r-1} \quad (r \text{ 은 임의의 실수})$$

$$\textcircled{2} \quad \frac{d}{dx} \{f(x) + g(x)\} = \frac{df(x)}{dx} + \frac{dg(x)}{dx}$$

$$\textcircled{3} \quad \frac{d}{dx} \{kf(x)\} = k \frac{df(x)}{dx}$$

### ■ 전미분(total differentiation)

⇒ 변수가 2개 이상인 다변수함수(multivariate function)의 미분

## 2.3 상미분과 편미분

### ■ 편미분(partial derivative)

☞ 다변수함수에 대하여, 그 중 하나의 변수에 주목하고 나머지 변수의 값을 고정시켜 놓고 그 변수로 미분하는 방법

◆ 예) 함수  $z = f(x, y) = 3x^2 + 2xy + 2y^2$

•  $x$ 에 대한 편미분 :  $y$ 를 상수로 보고  $x$ 로 미분

$$\frac{\partial f(x, y)}{\partial x} = \lim_{\Delta x \rightarrow 0} \frac{\Delta z}{\Delta x} = 6x + 2y$$

•  $y$ 에 대한 편미분 :  $x$ 를 상수로 보고  $y$ 로 미분

$$\frac{\partial f(x, y)}{\partial y} = \lim_{\Delta y \rightarrow 0} \frac{\Delta z}{\Delta y} = 2x + 4y$$

☞ 표기법

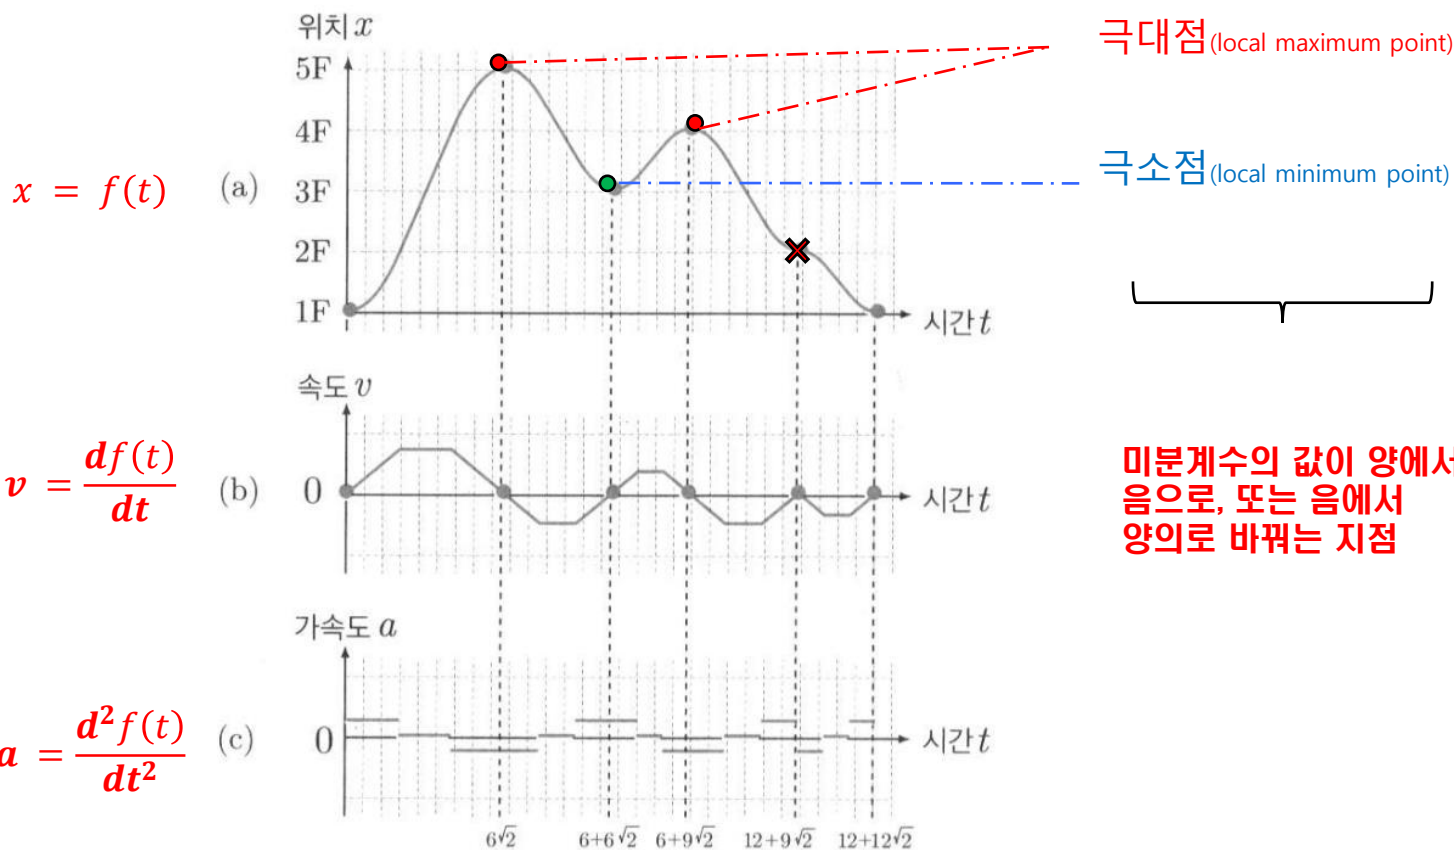
◆ 라이프니츠 표기법:  $\frac{\partial f(x, y)}{\partial x}, \frac{\partial f(x, y)}{\partial y}$

◆ 라그랑주 표기법:  $f_x(x, y), f_y(x, y)$

# 2.4 그래프 그리기

## ■ 그래프의 의미

☞ 예제) 엘리베이터가 1층→5층→3층→4층→2층→1층으로 이동, 시간  $t$ 에 대한 엘리베이터의 위치  $x$ 와 속도  $v$ , 그리고 가속도  $a$ 를 그래프 표현



# 2.4 그래프 그리기

## ■ 증감표

☞ 그래프의 특징을 표로 정리

시간 $t$	0	...	$2\sqrt{2}$	...	$4\sqrt{2}$	...	$6\sqrt{2}$	...	$2 + 6\sqrt{2}$	...	$4 + 6\sqrt{2}$	...	$6 + 6\sqrt{2}$	...
속도 $v = \frac{dx}{dt}$	0	+					0	-					0	+
가속도 $a = \frac{d^2x}{dt^2}$	$\searrow$	+	$\searrow$	0	$\searrow$		-	$\searrow$	0	$\searrow$		+	$\searrow$	
위치 $x$	1F	$\nearrow$	2F	$\nearrow$	4F	$\nearrow$	5F (극대)	$\searrow$	4.5F	$\searrow$	3.5F	$\searrow$	3F (극소)	$\nearrow$

극점 local extremum point  
극값 local extremum value

☞ 부호와 화살표 의미

$\frac{dx}{dt}$	$\frac{d^2x}{dt^2}$	화살표	의미
0	$\searrow$	$\rightarrow$	$x$ 는 일정 ( $\frac{dx}{dt} = 0$ )
+	+	$\nearrow$	$x$ 는 증가 ( $\frac{dx}{dt} > 0$ ) 하고, 증가율이 증가 ( $\frac{d^2x}{dt^2} > 0$ )
+	0	$\nearrow$	$x$ 는 증가 ( $\frac{dx}{dt} > 0$ ) 하고, 증가율이 일정 ( $\frac{d^2x}{dt^2} = 0$ )
+	-	$\nearrow$	$x$ 는 증가 ( $\frac{dx}{dt} > 0$ ) 하고, 증가율이 감소 ( $\frac{d^2x}{dt^2} < 0$ )
-	+	$\searrow$	$x$ 는 감소 ( $\frac{dx}{dt} < 0$ ) 하고, 감소율이 감소 ( $-\frac{d^2x}{dt^2} < 0$ )
-	0	$\searrow$	$x$ 는 감소 ( $\frac{dx}{dt} < 0$ ) 하고, 감소율이 일정 ( $-\frac{d^2x}{dt^2} = 0$ )
-	-	$\searrow$	$x$ 는 감소 ( $\frac{dx}{dt} < 0$ ) 하고, 감소율이 증가 ( $-\frac{d^2x}{dt^2} > 0$ )

## 2.5 함수의 최대값과 최소값

### ■ 규칙

- ⇒ 함수의 최대값, 최소값은 **극점**이나 구간의 양끝단에서 나온다.
- ⇒ 1계 미분한 값이 0일 때 **극값**을 구할 수 있다.

### ■ 인공지능에서는 이렇게 활용한다!


- ⇒ **최소제곱법(least square method)**은 여러 개의 오차들을 제공하고, 그 제곱들의 합이 최소가 되는 관계식을 구한 것으로, **선형회귀(linear regression)** 알고리즘에서 사용하는 최적화 기법입니다. 선형회귀 알고리즘은 인공지능 분야에서 자주 사용되는 기본 알고리즘 중의 하나입니다.
- ⇒  $f(a, b) = (\text{오차의 제곱들의 합})$ 이라고 가정할 때,  $\frac{\partial f(a, b)}{\partial a} = 0$ 이고  $\frac{\partial f(a, b)}{\partial b} = 0$ 이 되는 방정식을 풀면 오차의 제곱들을 합한 결과가 최소가 되는 관계식을 풀 수 있습니다.
- ⇒ 이런 풀이는 2차함수를 1계 미분한 함수의 값이 0일 때, 극값(최소 제곱법에서는 최소값)을 구할 수 있다는 특징을 잘 활용한 예입니다.

## 2.6.1 초등함수의 미분

### ■ 초등함수(elementary function)의 미분

원래 함수		원래 함수를 $x$ 로 미분한 것	
멱함수		$x^r$	$rx^{r-1}$
지수함수		$e^x, \exp(x)$	$e^x, \exp(x)$
		$a^x$	$a^x \log_e a$
로그함수		$\log_e x \ (x > 0)$	$\frac{1}{x}$
삼각함수	사인함수	$\sin x$	$\cos x$
	코사인함수	$\cos x$	$-\sin x$
	탄젠트함수	$\tan x$	$\frac{1}{\cos^2 x}$

### ■ 삼각함수 미분의 관계



## 2.6.2 합성함수의 미분

### ■ 합성함수의 미분(연쇄법칙, 곱의 법칙)

☞ 합성함수(변수가 1개)  $y = f(x)$ 의 미분법

- 연쇄법칙(chain rule)

$$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dv} \cdot \frac{dv}{dw} \cdot \frac{dw}{dx}$$

임의의 식을 끼워 넣습니다.

☞ 합성함수(변수가 여러 개)  $z = f(x, y)$ 의 미분법

- $\frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \cdot \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \cdot \frac{\partial v}{\partial x}$

☞ 곱의 법칙

- $\frac{d}{dx} \{f(x)g(x)\} = \frac{df(x)}{dx} g(x) + f(x) \frac{dg(x)}{dx}$



## 2.6.2 합성함수의 미분

⇒ 예제) 함수  $f(x) = (3x - 4)^{50}$ 을  $x$ 에 대해 미분 ( $u = 3x - 4$ )

$$\frac{df(x)}{dx} = \frac{du^{50}}{du} \cdot \frac{d(3x-4)}{dx} = 50u^{49} \cdot 3 = 150(3x - 4)^{49}$$

⇒ 예제) 함수  $f(x, y) = (3x + 1)^2 + (x + y + 1)^3$ 을  $x$ 에 대해 미분

$$u = 3x + 1, v = x + y + 1 \text{ 가정하면 } f(x, y) = u^2 + v^3$$

$$\begin{aligned}\frac{\partial f(x, y)}{\partial x} &= \frac{\partial u^2}{\partial u} \cdot \frac{\partial u}{\partial x} + \frac{\partial f(x, y)}{\partial v} \cdot \frac{\partial v}{\partial x} \\ &= 2u \cdot 3 + 3v^2 \cdot 1 \\ &= 6(3x + 1) + 3(x + y + 1)^2 \\ &= 3x^2 + (6y + 24)x + 3y^2 + 6y + 9\end{aligned}$$

⇒ 예제) 함수  $y = xe^x$ 를  $x$ 에 대해 미분( $f(x) = x, g(x) = e^x$ )

$$\begin{aligned}\frac{dy}{dx} &= \frac{df(x)}{dx} g(x) + f(x) \frac{dg(x)}{dx} \\ &= 1 \cdot e^x + x \cdot e^x \\ &= (1 + x)e^x\end{aligned}$$

$c$ 는 상수,  $n$ 은 임의의 실수일 때 함수  $f(x)$ 와  $g(x)$ 의 도함수가 존재하면 다음 관계식이 성립한다.

$$(1) \frac{d}{dx} [c] = 0$$

$$(2) \frac{d}{dx} [cf(x)] = cf'(x)$$

$$(3) \frac{d}{dx} [x^n] = nx^{n-1} \quad (1.5)$$

$$(4) \frac{d}{dx} [f(x) \pm g(x)] = f'(x) \pm g'(x)$$

$$(5) \frac{d}{dx} [f(x)g(x)] = f(x)g'(x) + f'(x)g(x)$$

$$(6) \frac{d}{dx} \left[ \frac{f(x)}{g(x)} \right] = \frac{f'(x)g(x) - f(x)g'(x)}{[g(x)]^2} \quad (g(x) \neq 0)$$

$$D_x u^r = ru^{r-1}u'(x)$$

$$D_x \ln u = \frac{1}{u}u'(x)$$

$$D_x e^u = e^u u'(x)$$

$$D_x \sin u = \cos u \cdot u'(x)$$

$$D_x \cos u = -\sin u \cdot u'(x)$$

$$D_x \tan u = \sec^2 u \cdot u'(x)$$

$$D_x \cot u = -\csc^2 u \cdot u'(x)$$

$$D_x \sec u = \sec u \tan u \cdot u'(x)$$

$$D_x \csc u = -\csc u \cot u \cdot u'(x)$$

$$D_x \sin^{-1} u = \frac{1}{\sqrt{1-u^2}} u'(x)$$

$$D_x \cos^{-1} u = -\frac{1}{\sqrt{1-u^2}} u'(x)$$

$$D_x \tan^{-1} u = \frac{1}{1+u^2} u'(x)$$


## 2.6.2 합성함수의 미분

### ■ 인공지능에서는 이렇게 활용한다!

- ⇒ 신경망에서는 학습한 결과로 도출된 답이 정답 데이터에 가까워질 수 있도록 가중치( $\omega$ )를 조정하는 과정을 반복합니다.
- ⇒ 이때, 실제 정답과 학습 결과 사이의 오차 값을 가중치로 편미분한 다음, 그 값을 가중치의 조정량으로 사용합니다.
- ⇒ 이렇게 편미분을 하는 과정에서 앞서 살펴본 연쇄법칙이 사용되는데, 이런 일련의 기법을 **오차역전파법(backpropagation)**이라고 합니다.



# 3장 선형대수



# 개 요

## 벡터, 행렬

### 특징

노름, 거리, 차원,  
내적, 행렬식

### 연산

벡터합, 스칼라곱,  
행렬합, 행렬곱

### 특수형태

영행렬, 음행렬, 단위행렬,  
역행렬, 대각행렬,  
전치행렬 등

### 선형문제

선형결합

기본행변환

가우스-조르단 소거법

### 알고리즘

LU분해

QR분해

최소제곱법

그람-슈미트 방법

### 행렬의 특성값

고윳값&고유벡터

특이값

특이값분해  
(SVD)

# "선형대수학"이란?

## ■ 선형대수학(Linear Algebra)이란?

- ⇒ 선형 방정식 문제를 풀기위해 사용되는 방법들을 연구하는 과목이다.
- ⇒ 해의 존재성, 그리고 해를 "효율적"으로 찾는 것이 목표이다.
- ⇒ 선형 시스템이 갖는 고유 특성을 이용하여 시스템을 분석한다.

## ■ 선형대수학의 적용분야

- ⇒ 다변수 시스템 분야
  - ◆ 기계공학, 로봇공학, 위성통신, 기상학 등...
- ⇒ 데이터를 취급하는 분야
  - ◆ 빅데이터 처리, 영상처리, 음향처리, 인공지능 등...

# IT기술과 선형대수

## 선형 데이터


```
target_date=> select target_date, target_time, server_time, server_time, cpu_index, cpu_index
```

target_date	target_time	server_time	server_time	cpu_index	cpu_index
2016-12-26	02:29:30	1482737402	2	12	1
2016-12-26	02:32:29	1482737582	2	13	1
2016-12-26	02:32:29	1482737582	2	13	1
2016-12-26	02:35:29	1482737762	2	14	1
2016-12-26	02:35:29	1482737762	2	14	1
2016-12-26	02:38:29	1482737942	2	15	1
2016-12-26	02:38:29	1482737942	2	15	1
2016-12-26	02:41:30	1482738123	2	16	1
2016-12-26	02:41:30	1482738123	2	16	1
2016-12-26	02:41:30	1482738302	2	17	1
2016-12-26	02:44:29	1482738482	2	18	1
2016-12-26	02:44:29	1482738482	2	18	1

## 행렬


$$\begin{pmatrix} A_{11} & A_{12} & A_{13} & \cdots & A_{1n} \\ A_{21} & A_{22} & A_{23} & \cdots & A_{2n} \\ A_{31} & A_{32} & A_{33} & \cdots & A_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ A_{m1} & A_{m2} & A_{m3} & \cdots & A_{mn} \end{pmatrix}$$

## 데이터 처리



## 데이터 분석

original data space




## 고속연산



# 컴퓨터공학과 선형대수

- 컴퓨터공학에서 자주 사용되는 선형 데이터는 선형대수에서 벡터 또는 행렬로 다룰 수 있다.

- 선형 데이터란 일렬로 나열되어 각 데이터의 순서(index)가 정의된 데이터를 의미한다.



## 선형 데이터의 대표적 종류

### 테이블 데이터

Name	Stage	Applying for	Application Dat
Aaron Buxton	Pending	Event Support Agent	11/1/2019
Miguel Silva	Active	Event Support Agent	11/3/2019
Eric Ishida	On hold	Event Support Agent	10/16/2019
Kadji Bell	Active	Account Manager	10/13/2019
David Power	On hold	Event Support Agent	11/3/2019
Babak Shammass	Active	Support Team Lead	10/18/2019
Charlotte de Crum	Closed	Event Support Agent	11/5/2019
Joshua Vanburen	Active	Account Manager	10/11/2019
Keiko Tanaka	On hold	Event Support Agent	11/3/2019

### 배열

Memory Location

200	201	202	203	204	205	206	■	■	■
U	B	F	D	A	E	C	■	■	■
0	1	2	3	4	5	6	■	■	■

Index


### 이미지





# 인공지능과 선형대수

- 잘 알려진 인공지능 모형 중 하나인 딥러닝 모형은 선형대수 모형으로 표현이 가능하다.



||

$$\begin{pmatrix} w_{11}^{(4)} & w_{12}^{(4)} & w_{13}^{(4)} & w_{14}^{(4)} \\ w_{21}^{(4)} & w_{22}^{(4)} & w_{23}^{(4)} & w_{24}^{(4)} \end{pmatrix} \left( \dots f \left( \begin{pmatrix} w_{11}^{(1)} & w_{12}^{(1)} & w_{13}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} & w_{23}^{(1)} \\ w_{31}^{(1)} & w_{32}^{(1)} & w_{33}^{(1)} \\ w_{41}^{(1)} & w_{42}^{(1)} & w_{43}^{(1)} \end{pmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \right) \right)$$

# 선형데이터의 표현 : 벡터&행렬

- 선형데이터는 다음과 같이 벡터 또는 행렬로 표현할 수 있다.

선형 데이터

	A	B
1	Student	Score
2	A	90점
3	B	87점
4	C	79점
5	D	84점
6	E	96점

벡터

$$\begin{matrix} \downarrow \\ \rightarrow \end{matrix} x = \begin{bmatrix} 90 \\ 87 \\ 79 \\ 84 \\ 96 \end{bmatrix}$$

선형 데이터

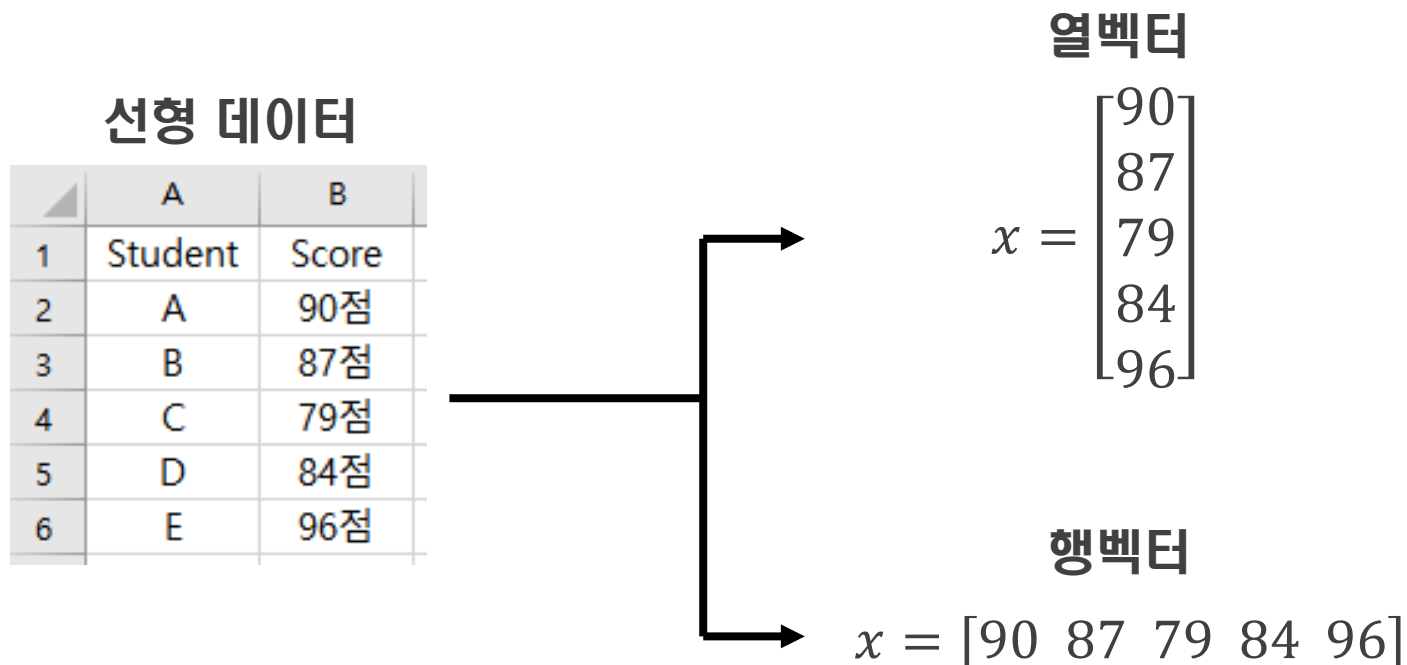
	A	B	C	D
1	Student	Score		
2		math	korean	english
3	A	90점	79점	80점
4	B	87점	61점	77점
5	C	79점	91점	86점
6	D	84점	88점	85점
7	E	96점	95점	100점


행렬

$$\begin{matrix} \downarrow \\ \rightarrow \end{matrix} X = \begin{bmatrix} 90 & 79 & 80 \\ 87 & 61 & 77 \\ 79 & 91 & 86 \\ 84 & 88 & 85 \\ 96 & 95 & 100 \end{bmatrix}$$

## 3.1 벡터

■ 벡터는 다음과 같이 두가지 형태로 나타낼 수 있다.





## 3.1 벡터

### ■ 벡터 성분

- 90, 87, 79, 84, 96는 벡터  $x$ 의 벡터 성분이다.
- 일반적으로 다음과 같이 표현한다.

$$x_1 = 90, x_2 = 87, \dots, x_5 = 96$$

### ■ n차원 벡터

- 벡터의 크기 = 벡터 성분의 개수
- 예시의 경우,  $x$ 는 5차원 벡터이다.

예시)

$$x = \begin{bmatrix} 90 \\ 87 \\ 79 \\ 84 \\ 96 \end{bmatrix}$$

## 3.2 벡터의 연산

### ■ 벡터합

$$x + y = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} + \begin{bmatrix} 1 \\ 2 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 + 1 \\ 2 + 2 \\ 3 + 1 \\ 4 + 2 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 4 \\ 6 \end{bmatrix}$$

### ■ 스칼라곱

$$\alpha x = 3 \times \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} = \begin{bmatrix} 3 \times 1 \\ 3 \times 2 \\ 3 \times 3 \\ 3 \times 4 \end{bmatrix} = \begin{bmatrix} 3 \\ 6 \\ 9 \\ 12 \end{bmatrix}$$

예시)


$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}, y = \begin{bmatrix} 1 \\ 2 \\ 1 \\ 2 \end{bmatrix},$$

$$\alpha = 3$$

## 3.2 벡터의 연산

### ■ 그래프 위의 표현(3.3 유향성분)


벡터 & 벡터성분




$x_1$ 와  $x_2$  는  
 $x$ 의 벡터성분

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$


벡터의 덧셈




스칼라곱



벡터의 뺄셈





# 영벡터와 음벡터

## ■ 영벡터

- 모든 벡터성분이 0인 벡터

예를들면,  $a = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$ ,  $b = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$

- 일반적으로 영벡터는 0으로 표현한다.

## ■ 음벡터

- 주어진 벡터의 모든 벡터성분에 -1을 곱한 벡터
- 간단하게,  $-x$ 을  $x$ 의 음벡터로 나타낸다.
- 주어진 예시에 대해 다음 벡터가 음벡터이다.

$$-x = \begin{bmatrix} -1 \\ -2 \\ -3 \end{bmatrix} \quad (\text{※ } x + (-x) = 0)$$

예시)

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$



## 3.4 벡터의 내적

### ■ 벡터의 내적

- $x \cdot y = \sum_{i=1}^n x_i y_i$

- 예를 들면,

$$x \cdot y = (1 \times 2) + (2 \times 3) + (1 \times 1) = 9$$

예시)

$$x = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, y = \begin{bmatrix} 2 \\ 3 \\ 1 \end{bmatrix}$$

### ■ Cauchy-Schwarz 부등식(Theorem)

For all vectors  $x$  and  $y$ ,

$$|x \cdot y| \leq ||x|| \times ||y||$$

### ■ 내적을 기하학적인 특징으로 정의 (두 벡터의 직교성은?)

벡터  $x$  와  $y$  가 이루는 각이  $\theta$  일 때 두 벡터의 내적은

$$x \cdot y = ||x|| ||y|| \cos \theta$$



## 3.7 벡터의 노름


### ■ 노름

- 벡터의 크기 또는 원점으로부터의 거리
- $\|x\| = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$
- 예를 들면,  $\|x\| = \sqrt{1^2 + 2^2 + 3^2} = \sqrt{14}$
- L1노름은 절대값의 합
- L2 노름은 유클리드 거리

예시)

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

### ■ 그래프 표현



# 벡터의 거리


## ■ 거리

-  $\|x - y\| = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$

- 예를 들면,

$$\|x - y\| = \sqrt{(1 - 2)^2 + (2 - 3)^2 + (1 - 1)^2} = \sqrt{2}$$

## ■ 그래프 표현



예시)

$$x = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, y = \begin{bmatrix} 2 \\ 3 \\ 1 \end{bmatrix}$$

## 3.8 코사인 유사도

### ■ 벡터의 내적으로부터

$$\cos \theta = x \cdot y / \|x\| \|y\|$$


$$\|x\| = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$$

$$\|y\| = \sqrt{\sum_{i=1}^n y_i^2} = \sqrt{y_1^2 + y_2^2 + \cdots + y_n^2}$$

- 코사인 유사도(Cosine Similarity)  $\cos(x, y)$

$$\cos(x, y) = \frac{x \cdot y}{\|x\| \|y\|} = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}}$$

$$\longrightarrow -1 \leq \cos(x, y) \leq 1 \quad (\text{두 벡터의 관계성})$$



## 3.9 행렬


선형 데이터

	A	B	C	D
1	Student	Score		
2		math	korean	english
3	A	90점	79점	80점
4	B	87점	61점	77점
5	C	79점	91점	86점
6	D	84점	88점	85점
7	E	96점	95점	100점



행렬

$$X = \begin{bmatrix} 90 & 79 & 80 \\ 87 & 61 & 77 \\ 79 & 91 & 86 \\ 84 & 88 & 85 \\ 96 & 95 & 100 \end{bmatrix}$$



5 행




3 열

벡터처럼 행렬도 행렬의 성분을 갖는다.

행렬은 " $n$  행,  $m$  열"의 크기를 갖는다.

예를들면,  $X$ 는 "5 행, 3 열인 행렬이다".





## 3.9 행렬

### ■ 다양한 형태의 행렬이 존재한다.

**정방행렬**

$$X = \begin{bmatrix} 3 & 9 & 0 \\ 4 & 1 & 2 \\ 5 & 1 & 5 \end{bmatrix}$$

**대각행렬**

$$X = \begin{bmatrix} 3 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 5 & 0 \\ 0 & 0 & 0 & 4 \end{bmatrix}$$

**영행렬**

$$X = \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

**대칭행렬**

$$X = \begin{bmatrix} 3 & 2 & 1 \\ 2 & 0 & 4 \\ 1 & 4 & 5 \end{bmatrix}$$

**상삼각행렬**

$$X = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 2 & 4 \\ 0 & 0 & 1 \end{bmatrix}$$

**열벡터와 답은 행렬**

$$X = \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix}$$



# 3.9.1 행렬의 벡터표현

선형 데이터

	A	B	C	D
1	Student	Score		
2		math	korean	english
3	A	90점	79점	80점
4	B	87점	61점	77점
5	C	79점	91점	86점
6	D	84점	88점	85점
7	E	96점	95점	100점

행렬

$$\begin{aligned}
 &\rightarrow X = \begin{bmatrix} 90 & 79 & 80 \\ 87 & 61 & 77 \\ 79 & 91 & 86 \\ 84 & 88 & 85 \\ 96 & 95 & 100 \end{bmatrix} \begin{matrix} w_1 \\ w_2 \\ w_3 \\ w_4 \\ w_5 \end{matrix} \\
 &\quad \quad \quad \begin{matrix} v_1 & v_2 & v_3 \end{matrix} \\
 &= \begin{bmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \\ x_{41} & x_{42} & x_{43} \\ x_{51} & x_{52} & x_{53} \end{bmatrix}
 \end{aligned}$$

행렬의 벡터표현

$$\begin{aligned}
 &\rightarrow X = [v_1 \ v_2 \ v_3] \\
 &\quad \quad \quad X = \begin{bmatrix} w_1 \\ w_2 \\ w_3 \\ w_4 \\ w_5 \end{bmatrix}
 \end{aligned}$$

## 3.9.2 행렬의 연산

### ■ 행렬의 덧셈

$$A + B = \begin{bmatrix} 1 & 1 \\ 2 & 0 \\ 3 & 1 \end{bmatrix} + \begin{bmatrix} 1 & 3 \\ 2 & 2 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1+1 & 1+3 \\ 2+2 & 0+2 \\ 3+1 & 1+1 \end{bmatrix} = \begin{bmatrix} 2 & 4 \\ 4 & 2 \\ 4 & 2 \end{bmatrix}$$

### ■ 행렬의 스칼라곱

$$\alpha A = 2 \times \begin{bmatrix} 1 & 1 \\ 2 & 0 \\ 3 & 1 \end{bmatrix} = \begin{bmatrix} 2 \times 1 & 2 \times 1 \\ 2 \times 2 & 2 \times 0 \\ 2 \times 3 & 2 \times 1 \end{bmatrix} = \begin{bmatrix} 2 & 2 \\ 4 & 0 \\ 6 & 2 \end{bmatrix}$$

예시)

$$A = \begin{bmatrix} 1 & 1 \\ 2 & 0 \\ 3 & 1 \end{bmatrix},$$

$$B = \begin{bmatrix} 1 & 3 \\ 2 & 2 \\ 1 & 1 \end{bmatrix},$$

$$\alpha = 2$$

### 3.9.3 영행렬과 음행렬

#### ■ 영행렬

- 행렬의 모든 성분이 0인 행렬

예를 들면,  $A = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$ ,  $B = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$

- 일반적으로 영행렬을 0으로 표현한다.

예시)


$$A = \begin{bmatrix} 1 & 2 & 2 \\ 2 & 1 & 3 \\ 3 & 0 & 4 \end{bmatrix}$$

#### ■ 음행렬

- 주어진 행렬의 모든 성분에 -1을 곱하여 만든 행렬  $-A$ .
- 예를들면,

$$-A = \begin{bmatrix} -1 & -2 & -2 \\ -2 & -1 & -3 \\ -3 & 0 & -4 \end{bmatrix} \quad * \quad A + (-A) = 0$$





## 3.9.4 전치행렬과 대칭행렬

### ■ 전치행렬

- **전치행렬**이란 대각성분을 기준으로 모든 성분의 행과 열의 위치를 바꾼 행렬이다.
- 예를들면,

$$A = \begin{bmatrix} 1 & 4 \\ 2 & 1 \\ 3 & 0 \end{bmatrix} \Rightarrow A^T = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 1 & 0 \end{bmatrix}$$

### ■ 대칭행렬

- 만약 주어진 행렬이 " $A = A^T$ "라면, 행렬  $A$ 를 **대칭행렬** 이라한다.

예를들면,

$$X = \begin{bmatrix} 3 & 2 & 1 \\ 2 & 0 & 4 \\ 1 & 4 & 5 \end{bmatrix}$$



## 3.10 행렬의 곱셈

### ■ 행렬곱(행렬-행렬곱)







$$\begin{bmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \end{bmatrix} \begin{bmatrix} a_1 & a_2 \\ b_1 & b_2 \\ c_1 & c_2 \end{bmatrix} = \begin{bmatrix} x_{11}a_1 + x_{12}b_1 + x_{13}c_1 & x_{11}a_2 + x_{12}b_2 + x_{13}c_2 \\ x_{21}a_1 + x_{22}b_1 + x_{23}c_1 & x_{21}a_2 + x_{22}b_2 + x_{23}c_2 \end{bmatrix}$$

예를 들면,

$$\begin{bmatrix} 1 & 2 & 3 \\ 2 & 0 & 1 \\ 3 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 0 & 4 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 1 \times 1 + 2 \times 0 + 3 \times 2 & 1 \times 2 + 2 \times 4 + 3 \times 1 \\ 2 \times 1 + 0 \times 0 + 1 \times 2 & 2 \times 2 + 0 \times 4 + 1 \times 1 \\ 3 \times 1 + 1 \times 0 + 1 \times 2 & 3 \times 2 + 1 \times 4 + 1 \times 1 \end{bmatrix} = \begin{bmatrix} 7 & 13 \\ 4 & 5 \\ 5 & 11 \end{bmatrix}$$


## 3.10 행렬의 곱셈

### ■ 행렬연산의 기하학적 이해



# 행렬곱의 그래프 표현


행렬-벡터곱



\* 행렬을 열벡터들의 모임으로 생각한다면, 행렬-벡터곱은 열벡터들로 새로운 벡터를 만들어낸다.

행렬-행렬곱

$$AB = [Au \quad Av]$$



\* 행렬-벡터곱으로 만든 여러개의 열벡터를 모아 새로운 행렬을 만들어낸다.

예시)

$$A = \begin{bmatrix} x_1 & y_1 \\ x_2 & y_2 \end{bmatrix} = [x \quad y]$$

$$w = \begin{bmatrix} \alpha \\ \beta \end{bmatrix}$$

$$B = \begin{bmatrix} \alpha_1 & \alpha_2 \\ \beta_1 & \beta_2 \end{bmatrix} = [u \quad v]$$

## 3.10.1 행렬-벡터곱

### ■ 행렬-벡터곱

$$\begin{bmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} x_{11}a + x_{12}b + x_{13}c \\ x_{21}a + x_{22}b + x_{23}c \\ x_{31}a + x_{32}b + x_{33}c \end{bmatrix}$$


예를 들면,

$$Ax = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 0 & 1 \\ 3 & 1 & 1 \end{bmatrix} \begin{bmatrix} 4 \\ 5 \\ 6 \end{bmatrix} = \begin{bmatrix} 1 \times 4 + 2 \times 5 + 3 \times 6 \\ 2 \times 4 + 0 \times 5 + 1 \times 6 \\ 3 \times 4 + 1 \times 5 + 1 \times 6 \end{bmatrix} = \begin{bmatrix} 32 \\ 14 \\ 23 \end{bmatrix}$$

예시)

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 0 & 1 \\ 3 & 1 & 1 \end{bmatrix},$$

$$x = \begin{bmatrix} 4 \\ 5 \\ 6 \end{bmatrix},$$



# 단위행렬

## ■ 단위행렬

- 모든 대각성분이 1로 이루어진 대각행렬.

예를 들면,  $I_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ ,  $I_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$

- 모든 정방행렬  $A$ 에 대해,

$$AI = IA = A$$

예를 들면,

$$AI = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 0 & 1 \\ 3 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 0 & 1 \\ 3 & 1 & 1 \end{bmatrix} = A$$





## 3.11 역행렬

### ■ 역행렬


- 주어진 정방행렬  $A$ 에 대해,  
만약  $AA^{-1} = A^{-1}A = I$ 를 만족하는  $A^{-1}$ 가 있다면,  
 $A^{-1}$ 를  $A$ 의 역행렬이라 한다.

예를 들면,

$$1) AB = \begin{bmatrix} 4 & 3 \\ 3 & 2 \end{bmatrix} \begin{bmatrix} -2 & 3 \\ 3 & -4 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \Rightarrow B = A^{-1}$$

$$2) CD = \begin{bmatrix} 2 & 3 & -1 \\ 4 & 4 & -3 \\ -2 & 3 & -1 \end{bmatrix} \begin{bmatrix} \frac{1}{4} & 0 & -\frac{1}{4} \\ \frac{1}{2} & -\frac{1}{5} & \frac{1}{10} \\ 1 & -\frac{3}{5} & -\frac{1}{5} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \Rightarrow D = C^{-1}$$





# 정 리

벡터, 행렬		
특징	연산	특수형태
노름, 거리, 차원, 내적, 행렬식	벡터합, 스칼라곱, 행렬합, 행렬곱	영행렬, 음행렬, 단위행렬, 역행렬, 대각행렬, 전치행렬 등

