




# 인공지능수학

(선형대수학)



# 개요

## 벡터, 행렬

### 특징

노름, 거리, 차원,  
내적, 행렬식

### 연산

벡터합, 스칼라곱,  
행렬합, 행렬곱

### 특수형태

영행렬, 음행렬, 단위행렬,  
역행렬, 대각행렬,  
전치행렬 등

### 선형문제

선형결합

기본행변환

가우스-조르단 소거법

### 알고리즘

LU분해

QR분해

최소제곱법

그람-슈미트 방법

### 행렬의 특성값

고윳값&고유벡터

특잇값

특잇값분해  
(SVD)

# 벡터공간

## ■ 벡터공간(Vector space)

☞ 벡터를 포함하고 있는 집합이 다음 조건들을 모두 만족하는 경우,  
이 집합을 벡터공간이라 한다.


- ◆ 벡터합 :  $x, y \in X \Rightarrow x + y \in X$
- ◆ 스칼라곱 :  $\alpha \in \mathfrak{R}, x \in X \Rightarrow \alpha x \in X$

← 스칼라[Scalar]

## ■ 생성(Span)

☞ 벡터합과 스칼라곱을 이용하여 주어진 벡터들로 벡터공간을 만드는 것.


**선형결합 = 벡터합과 스칼라곱을 이용한 벡터결합**



# 일반적인 선형방정식 문제

다음 방정식의 해는 무엇인가?

$$\begin{cases} 3x + 2y = 1 \\ 2x + 2y = 2 \end{cases} \quad \text{or} \quad \begin{pmatrix} 3 & 2 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$




$$\text{방정식의 해는 } \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} -1 \\ 2 \end{pmatrix}$$



# 일반적인 선형방정식 문제

다음 방정식의 해는 무엇인가?

$$\begin{cases} 4x + 2y = 2 \\ 2x + y = 1 \end{cases} \text{ or } \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$




방정식의 해는  $\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} \alpha \\ 1 - 2\alpha \end{pmatrix}$

해가 무수히 많다(부정)

# 일반적인 선형방정식 문제

다음 방정식의 해는 무엇인가?

$$\begin{cases} 3x + 2y = 1 \\ 3x + 2y = 2 \end{cases} \quad \text{or} \quad \begin{pmatrix} 3 & 2 \\ 3 & 2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$



**해가 존재하지 않는다(불능)**



# 일반적인 선형방정식 문제

## 선형방정식 문제의 분류

해가 존재하는 경우

유일하게 해가 존재함

해가 무수히 존재함



LU분해

해가  
존재하지 않는 경우

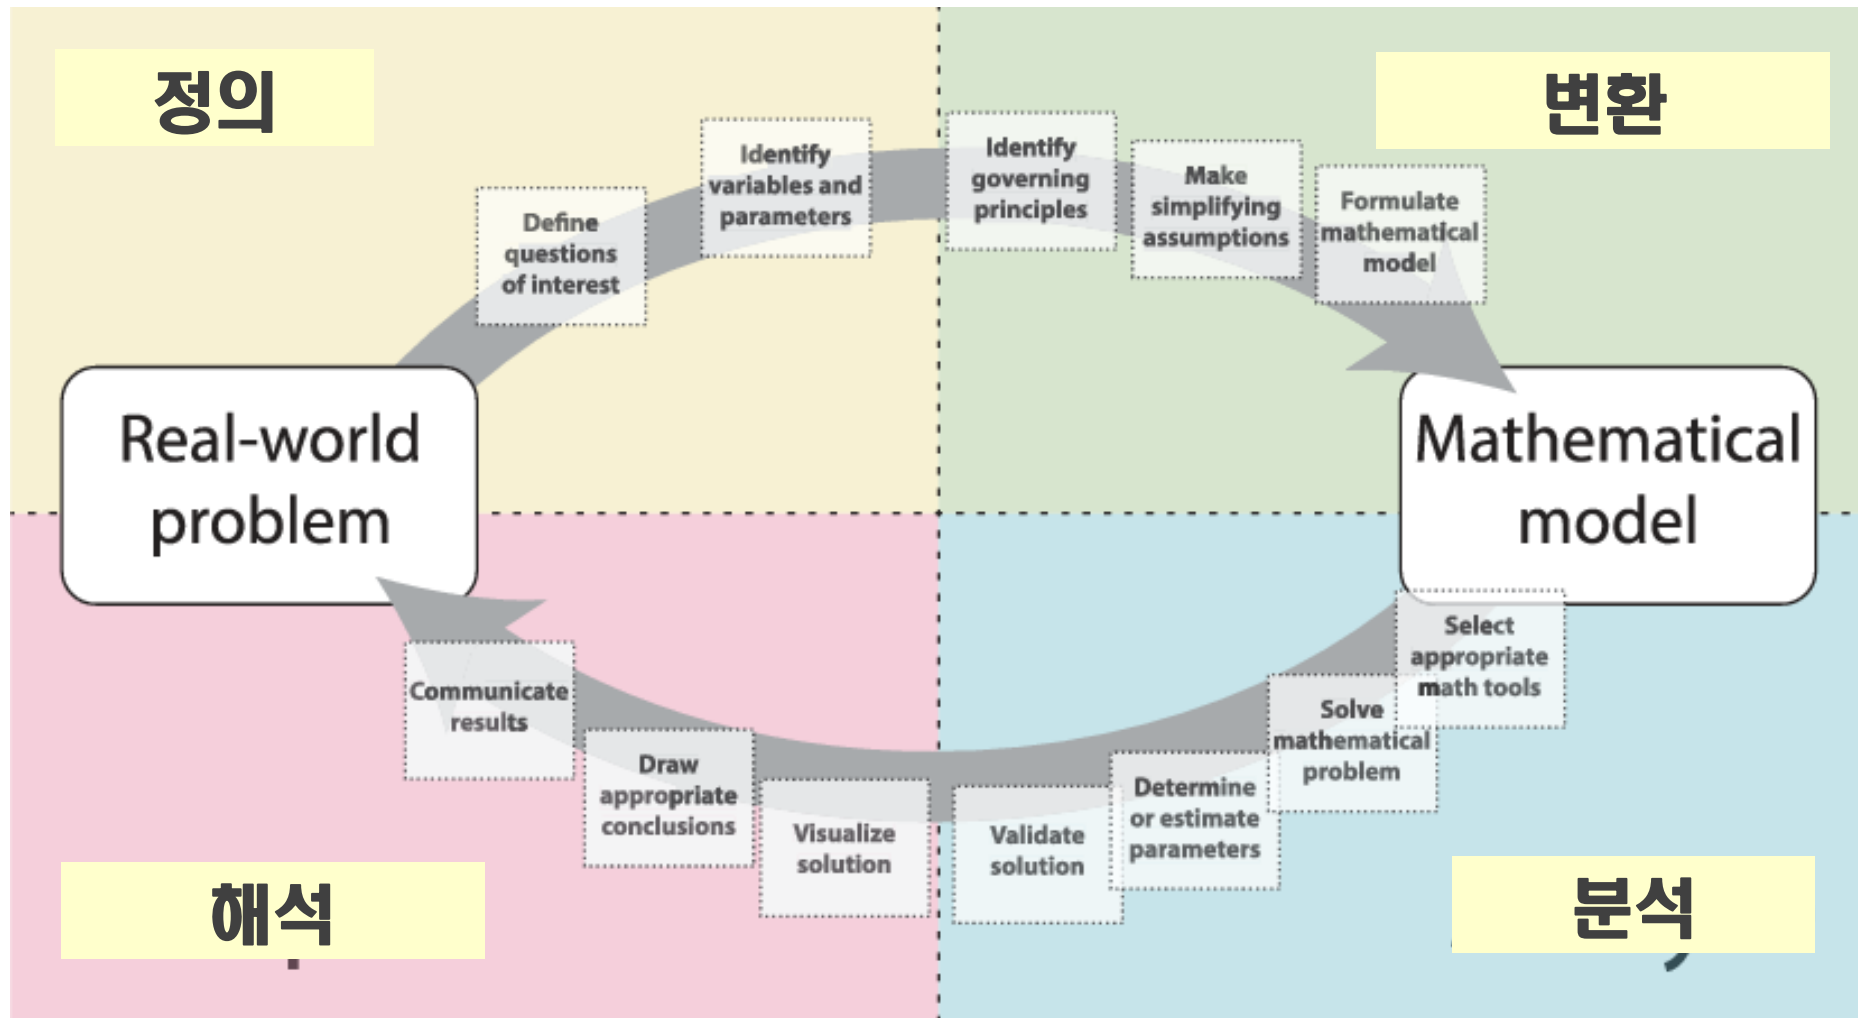
**불능**



**회귀문제!**



# 수학적 모델링





# 수학적 모델링


## 변환

Identify governing principles


Make simplifying assumptions

Formulate mathematical model

Mathematical model



↓ Making simplifying assumptions




↓ Formulate mathematical model

$$f(x) = ax + b$$

# 회귀(Regression)

## 회귀(Regression)


- 일반적으로 우리가 수집한 데이터에는 노이즈가 포함되어 있기 때문에 정확한 모델을 구할수 없다. 하지만 이러한 데이터를 가지고 분석을 하고자 한다.
- Regression은 노이즈가 포함된 데이터의 분석을 위해 데이터들의 근사모형을 찾아내는 방법이다.




# 회귀(Regression)

빨간 선만큼의 차이들의 합 = Error


## 1) 초기화




## 2) 가장 작은 error를 갖는 $f$ 찾기



## 3) 새로운 값 입력




## 4) 값을 예측하기 위해 $f(x)$ 적용



# 선형회귀(Linear Regression)

## Linear Regression

- 가장 작은 **error**를 갖는 선형함수  $f$  찾기



최소제곱오차

$$f = \min (\sum_i |y_i - f(x_i)|^2)$$


어떻게해야  $f$  를 찾을 수 있을까?



# 해가 없는 선형방정식 문제


다음 방정식을 다시 생각해보자.

$$\begin{cases} 3x + 2y = 1 \\ 3x + 2y = 2 \end{cases} \quad \text{or} \quad \begin{pmatrix} 3 & 2 \\ 3 & 2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$




- 1) 해가 없는 선형방정식  $Ax = b$ 의 오차를  $w = Ax - b$ 로 둘 수 있다.
- 2) 오차  $w$ 의 크기는 노름  $\|w\|$ 로 구할 수 있다.





# 해가 없는 선형방정식 문제

오차  $w$ 가 최소가 되는  $x$ 는 무엇인가?




$\|Ax - b\|$ 를 최소화하는  $x$ 를 찾아야한다.

위의 조건을 만족하는  $x$ 를 구하려면 어떻게 해야할까?

힌트 1.  $\|Ax - b\|$ 는 항상 0보다 크기때문에 극솟값이 존재한다.


힌트 2. 극솟값 또는 극댓값에서는 미분계수가 0이다.





# 해가 없는 선형방정식 문제

오차  $w$ 가 최소가 되는  $x$ 는 무엇인가?




$\|Ax - b\|$ 를 최소화하는  $x$ 를 찾아야한다.

방정식  $\frac{\partial(\|Ax-b\|)}{\partial x} = 0$ 를 만족하는 해  $x$ 를 구하는 문제

벡터의 미분?






# 벡터의 미분

## ■ 벡터 미분

$\frac{\partial y}{\partial \mathbf{x}}$	<p>함수 <math>y</math>를 벡터 <math>\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}</math>로 미분한 값은 다음과 같다.</p> $\frac{\partial y}{\partial \mathbf{x}} = \left( \frac{\partial y}{\partial x_1} \quad \frac{\partial y}{\partial x_2} \quad \cdots \quad \frac{\partial y}{\partial x_n} \right)$
$\frac{\partial \mathbf{y}}{\partial x}$	<p>벡터함수 <math>\mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}</math>를 스칼라 <math>x</math>로 미분한 값은 다음과 같다.</p> $\frac{\partial \mathbf{y}}{\partial x} = \begin{pmatrix} \frac{\partial y_1}{\partial x} \\ \vdots \\ \frac{\partial y_m}{\partial x} \end{pmatrix}$








# 벡터의 미분

## ■ 벡터 미분

$\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$	<p>벡터함수 <math>\mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}</math>를 벡터 <math>\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}</math>로 미분한 값.</p> $\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} & \dots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \vdots & & \vdots \\ \frac{\partial y_m}{\partial x_1} & \frac{\partial y_m}{\partial x_2} & & \frac{\partial y_m}{\partial x_n} \end{pmatrix}$
---	--





# 벡터의 미분


## ■ 벡터 미분

두 벡터  $x, y$ 의 내적  $x \cdot y$ 를  $x$ 로 미분하면?

$$x \cdot y = x^T y = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n$$

$$\begin{aligned} \Rightarrow \frac{\partial x \cdot y}{\partial x} &= \left( \frac{\partial x \cdot y}{\partial x_1} \quad \frac{\partial x \cdot y}{\partial x_2} \quad \cdots \quad \frac{\partial x \cdot y}{\partial x_n} \right) \\ &= \left( \frac{\partial (x_1 y_1 + \cdots + x_n y_n)}{\partial x_1} \quad \cdots \quad \frac{\partial (x_1 y_1 + \cdots + x_n y_n)}{\partial x_n} \right) \\ &= (y_1 \quad y_2 \quad \cdots \quad y_n) \\ &= y^T \end{aligned}$$






# 벡터의 미분

## ■ 벡터 미분

### 벡터미분 간단정리


식	$x$ 에 대한 미분
$x \cdot y = x^T y$	$y^T$
$y \cdot x = y^T x$	$y^T$
$Ax$	$A$
$x^T A = (A^T x)^T$	$A^T$
$  x  ^2 = x \cdot x$	$2x^T$





# 해가 없는 선형방정식 문제 : 최소제곱법

오차  $w$ 가 최소가 되는  $x$ 는 무엇인가?



$\|Ax - b\|$ 를 최소화하는  $x$ 를 찾아야한다.

방정식  $\frac{\partial(\|Ax - b\|)}{\partial x} = 0$ 를 만족하는 해  $x$ 를 구하는 문제



# 해가 없는 선형방정식 문제 : 최소제곱법

방정식  $\frac{\partial(\|Ax-b\|)}{\partial x} = 0$ 를 만족하는 해  $x$


**Solve)**  $(Ax - b)^T(Ax - b) = (x^T A^T - b^T)(Ax - b)$  ※  $\|x\| = \sqrt{x^T x}$

$$= x^T A^T A x - x^T A^T b - b^T A x + b^T b$$

$$\Rightarrow \frac{\partial(x^T A^T A x - x^T A^T b - b^T A x + b^T b)}{\partial x} = 2x^T A^T A - 2b^T A = 0$$

$$\Rightarrow 2A^T A x = 2A^T b$$

$$\Rightarrow x = (A^T A)^{-1} A^T b$$



의사 역행렬  
(Pseudoinverse matrix)


$$x = (A^T A)^{-1} A^T b$$

최소제곱해

# 선형회귀 : 최소제곱법

## 최소제곱법

Input




데이터셋 :  $(d_1, v_1), (d_2, v_2), \dots, (d_n, v_n)$

데이터 :  $d_1, d_2, \dots, d_n$

라벨 :  $v_1, v_2, \dots, v_n$


Output



$$\text{선형모델 } f : \begin{cases} ad_1 + b \approx v_1 \\ ad_2 + b \approx v_2 \\ \vdots \\ ad_n + b \approx v_n \end{cases}$$

# 선형회귀 : 최소제곱법

## 최소제곱법



데이터셋 :  $(d_1, v_1), (d_2, v_2), \dots, (d_n, v_n)$

데이터 :  $d_1, d_2, \dots, d_n$

라벨 :  $v_1, v_2, \dots, v_n$

## Method

1) 
$$A = \begin{pmatrix} d_1 & 1 \\ d_2 & 1 \\ \vdots & \vdots \\ d_n & 1 \end{pmatrix} \quad v = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix}$$

2) 다음을 계산함

$$w = (A^T A)^{-1} A^T v$$


3)  $w = \begin{pmatrix} a \\ b \end{pmatrix}$ 를 이용하여

다음 선형함수  $f(x) = ax + b$  생성

# 선형회귀 : 최소제곱법

## 최소제곱법 : 3차 이상의 선형방정식의 경우

### Extension



$$\text{고차함수 } g : \begin{cases} ad_1^2 + bd_1 + c \approx v_1 \\ ad_2^2 + bd_2 + c \approx v_2 \\ \vdots \\ ad_n^2 + bd_n + c \approx v_n \end{cases}$$

$$h : \begin{cases} ad_1^3 + bd_1^2 + cd_1 + d \approx v_1 \\ ad_2^3 + bd_2^2 + cd_2 + d \approx v_2 \\ \vdots \\ ad_n^3 + bd_n^2 + cd_n + d \approx v_n \end{cases}$$

### Method

$$1) \quad A = \begin{pmatrix} d_1^2 & d_1 & 1 \\ d_2^2 & d_2 & 1 \\ \vdots & \vdots & \vdots \\ d_n^2 & d_n & 1 \end{pmatrix} \quad v = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix}$$

### 2) 다음을 계산함

$$w = (A^T A)^{-1} A^T v,$$
$$w^T = [a, b, c]$$

### 3) $w$ 를 이용하여

2차 함수  $g(x) = ax^2 + bx + c$  생성

$w$ 이  $n$ 차 벡터이기 때문에  
 $n$ 차 함수를 항상 만들 수 있다.





# 선형회귀 : 최소제곱법

## 최소제곱법

예시.

데이터

가격	판매량
1500	350
1700	340
1900	320
2100	300
2300	250
2500	240



$A$ 와  $v$  생성 .....  $w = (A^T A)^{-1} A^T v = \begin{pmatrix} -0.12 \\ 540 \end{pmatrix}$



# 행렬 A의 기본 공간 (Fundamental Spaces)



주어진  $m \times n$  행렬  $A$ 에 대해

행공간 (row space)  $\text{row}(A) = \text{span}(A \text{의 행벡터}) ; \mathbb{R}^n$ 의 부분공간

열공간 (column space)  $\text{col}(A) = \text{span}(A \text{의 열벡터}) ; \mathbb{R}^m$ 의 부분공간

영공간 (null space)  $\text{null}(A) = \{ x \in \mathbb{R}^n \mid Ax=0 \} ; \mathbb{R}^n$ 의 부분공간

$$\text{row}(A) = \text{col}(A^T), \text{row}(A^T) = \text{col}(A)$$

따라서 행렬  $A$ 의 기본공간은  $\text{row}(A)$ ,  $\text{col}(A)$ ,  $\text{null}(A)$ ,  $\text{null}(A^T)$  4 개





## 해가 없는 선형방정식

$Ax$  와  $w$  가 서로 수직일때,  $x$  는 무엇인가?

[힌트.  $a$  와  $b$  가 직교(orthogonal) 한다면 ,  $a \cdot b = 0$ ]

풀이과정) 어떤  $x$ 에 대해,  $(Ax) \cdot w = 0$

$$\Rightarrow A^T w = A^T (Ax - b) = 0 \quad (*\text{아래의 특징에 의해})$$

$$\Rightarrow A^T Ax = A^T b$$

$$\Rightarrow x = (A^T A)^{-1} A^T b$$

$$[*\text{특징 : } (Ax) \cdot w = 0 \Leftrightarrow A^T w = 0)$$

**\*\* 추가설명 :**

$w$ 가  $A$ 의 직교여공간에 있으면,  $w$ 는  $A^T$ 의 영공간에 있다.



## 해결되지 않은 선형방정식

$Ax$  와  $w$  가 직교 할 때,  $x$  는 무엇인가?

[힌트.  $a$  와  $b$  가 직교할 때,  $a \cdot b = 0$ ]

풀이과정) 어떤  $x$  에 대해 ,  $(Ax) \cdot w = 0$

$$\Rightarrow A^T w = A^T (Ax - b) = 0 \quad (*\text{by the property})$$

$$\Rightarrow A^T Ax = A^T b$$

$$\Rightarrow x = (A^T A)^{-1} A^T b$$

(\*Property :  $(Ax) \cdot w = 0 \Leftrightarrow A^T w = 0$ )

\*\* 추가설명 :  $w$ 가  $A$ 의 직교여공간에 있으면,  $w$ 는  $A^T$ 의 영공간에 있다.

## 해결되지 않은 선형 연립방정식 $Ax = b$

$Ax$  와  $w = Ax - b$  가 직교 할 때 ,  $x$  는 무엇인가?  
[힌트.  $a$  와  $b$  가 직교 할 때 ,  $a \cdot b = 0$ ]

풀이과정) 어떤  $x$  에 대해 ,  $(Ax) \cdot w = 0$

$$\Rightarrow A^T w = A^T (Ax - b) = 0 \quad (*\text{by the property})$$

$$\Rightarrow A^T Ax = A^T b$$

$$\Rightarrow x = (A^T A)^{-1} A^T b$$

[\*특징 :  $(Ax) \cdot w = 0 \Leftrightarrow A^T w = 0$ ]


의사 역행렬  
(Pseudoinverse matrix)

$$x = (A^T A)^{-1} A^T b$$

최소제곱법  $Ax = b$


## 직교성

서로 수직



$v_1$  와  $v_2$  가 서로 수직,  $v_1 \cdot v_2 = 0$

서로 수직



$v_1$  와  $v_2$  가 서로 수직

$$\begin{aligned} v_1 \cdot v_2 &= 0, \\ |v_1| &= 1, \\ |v_2| &= 1 \end{aligned}$$

## 직교성

### 직교벡터

$v_1, v_2, \dots, v_n$  가 서로 직교한다면,


- 1) 모든  $i$  and  $j$  에 대해 ,  $v_i \cdot v_j = 0$
- 2) 모든  $i$  에 대해 ,  $|v_i| = 1$

### 직교행렬

$v_1, v_2, \dots, v_n$  이 서로 직교하는 벡터이고,  
 $A = [v_1 \ v_2 \ \dots \ v_n]$  이 행렬임,

$A$  : 직교행렬

## 투영



투영된  $\text{proj}_a(b)$ 의 norm =  $|b|\cos\theta$

$$\times \quad |a||b|\cos\theta = a \cdot b$$

$$\Rightarrow |\text{proj}_a(b)| = |b|\cos\theta = \frac{a \cdot b}{|a|}$$

따라서,

$$\text{proj}_a(b) = (|b|\cos\theta) \frac{a}{|a|} = \frac{a \cdot b}{|a|^2} a$$



## 그람-슈미트 방법(Gram-Schmidt process)

입력 : 행렬

$$A = [v_1 \ v_2 \ \cdots \ v_n]$$

출력 : 직교행렬

$$Q = [u_1 \ u_2 \ \cdots \ u_n]$$

직교벡터 찾는 방법

$$u_1 = v_1$$

$$u_2 = v_2 - \text{proj}_{u_1}(v_2)$$

$$u_3 = v_3 - \text{proj}_{u_1}(v_3) - \text{proj}_{u_2}(v_3)$$

$$\vdots$$


$$u_n = v_n - \sum_{i=1}^{k-1} \text{proj}_{u_i}(v_n)$$



## QR분해

QR 분해가 왜 필요한가? (두가지 이유)

1. 선형회귀를 정확하게 계산
2. 다음에 배울 고유값을 구하기 위한 필요한 핵심 분해 기법.
3. 고유값과 고유값을 구하는 방법은 이후에 소개할 것이다.



# 정 리

## 벡터, 행렬

### 특징

노름, 거리, 차원,  
내적, 행렬식

### 연산

벡터합, 스칼라곱,  
행렬합, 행렬곱

### 특수형태

영행렬, 음행렬, 단위행렬,  
역행렬, 대각행렬,  
전치행렬 등

### 선형문제

선형결합

기본행변환

가우스-조르단 소거법

### 알고리즘

LU분해

QR분해

최소제곱법

그람-슈미트 방법

### 행렬의 특성값

고윳값&고유벡터

특잇값

특잇값분해  
(SVD)

# Q & A

---

