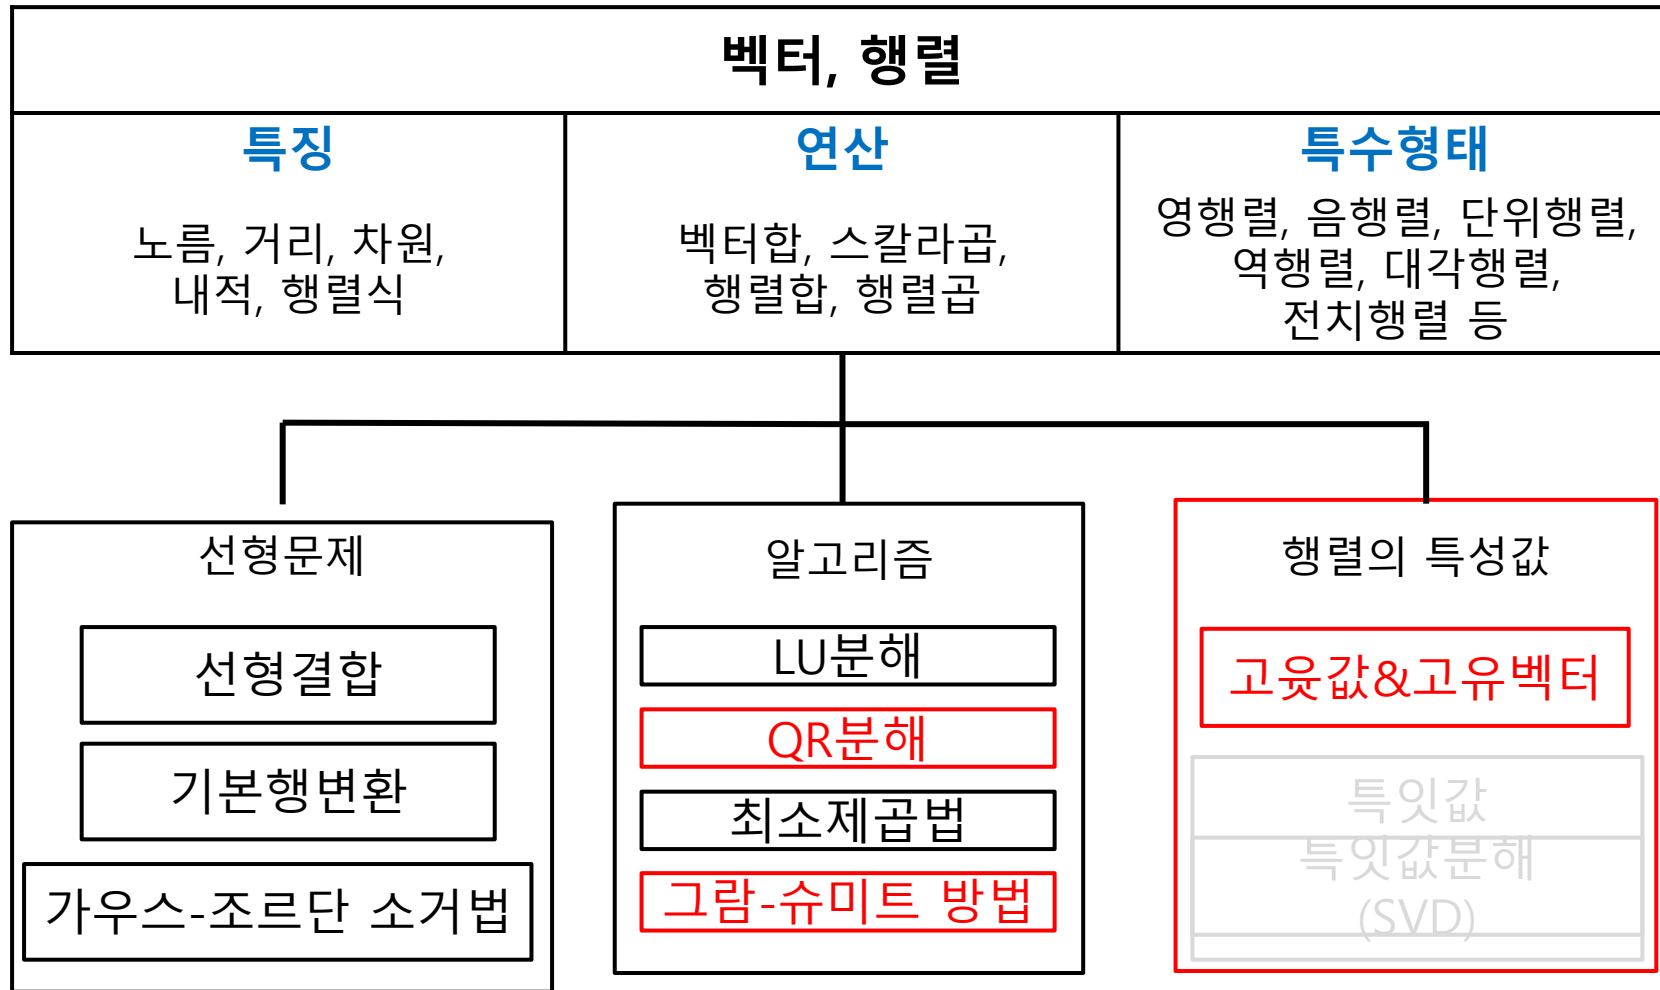


인공지능수학

(선형대수학2)



개 요





Gram-Schmidt 방법

Gram-Schmidt 방법

Definition

Gram-Schmidt: 내적 공간 (inner product space)에서 유한 개의 선형 독립 벡터 집합을 정규 직교 기저 (orthonormal basis)로 변환하는 방법입니다.

때문에 그람 슈미트 과정 (Gram-Schmidt Process) 또는 그람 슈미트 단위 직교화 (Gram-Schmidt orthonormalization)이라고 부릅니다.

Gram-Schmidt 방법

Why?

그람 슈미트 과정의 필요성은 다음과 같습니다. 흔히 우리가 다루는 3차원 공간에는 x, y, z 축이 있으며 각 축에 대한 기저가 존재합니다. 이것들을 우리는 standard basis라고도 부르며 해당 기저들은 서로 독립이기 때문에 다른 벡터를 표현할 때 basis의 조합으로 표현이 가능합니다.

$$e_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad e_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \quad e_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

3차원에서의 standard basis

standard basis와 같이 직교성을 갖는 기저는 많은 연산과정에서 편리하다는 장점이 있습니다. 즉 직교 기저에 의해서 생성되는 공간의 벡터들을 표현하기 위해서 기저에 특정한 가중치들을 가진 선형 결합으로서 쉽게 표현이 가능한 장점이 생깁니다.

Gram-Schmidt 방법

Gram-Schmidt과정 또한 어떤 벡터들이 span하는 공간에 대해 공간을 대표하는 basis를 찾는 과정입니다.

Gram-Schmidt 과정을 통해서 나온 basis의 특성은 다음과 같습니다. basis끼리 직교 (Orthogonal)이며 정규화된 (Normalized) 값입니다. 즉 정규 직교 (Orthonormal) basis를 얻게 됩니다.


*직교 (Orthogonality): 두 벡터의 내적이 0값을 가지는 것 (또는 선형 독립일 때)

*정규화 (Normalization): 벡터를 벡터의 norm으로 나눈 것 (때문에 정규화된 벡터는 최대 크기가 1 이하로 됨)

Gram-Schmidt 방법

2D example

아래 그림을 보겠습니다. 우선 내적 공간 V 의 기저 $\{v_1, v_2\}$ 가 주어져 있습니다.



[1] Gram-Schmidt 과정의 기본 원리

v_1 과 v_2 는 선형 독립이며 이때 v_1 과 v_2 가 만들어내는 벡터 공간의 직교 벡터는 u_1 과 u_2 입니다. 그리고 u_1 과 u_2 를 단위 벡터 (또는 정규화) 생성 과정을 통해서 정규 직교 기저 (Orthonormal basis)은 e_1 과 e_2 가 되며 해당 e_1 과 e_2 를 찾는 과정이 Gram-Schmidt입니다.

Gram-Schmidt 방법

순서는 다음과 같습니다.

1. 먼저 하나의 기준 벡터를 선정합니다.

임의의 벡터 u_1 은 제시된 벡터와 동일하게 둡니다 ($u_1 = v_1$)

$$u_1 = v_1$$

2. u_1 에 수직 (Orthogonal)한 벡터인 u_2 를 찾기 위해서 먼저 v_2 를 v_1 (또는 u_1)에 정사영 (Projection)합니다.

정사영된 벡터를 v_2 에 빼줌으로써 u_2 를 찾을 수 있습니다.

$$u_2 = v_2 - \text{proj}_{u_1} v_2 = v_2 - \frac{v_2 \cdot u_1}{u_1 \cdot u_1} u_1$$

Gram-Schmidt 방법


3. u_1 과 u_2 를 모두 찾았으니 정규화를 합니다.

$$\begin{aligned} e_1 &= u_1 / \|u_1\| \\ e_2 &= u_2 / \|u_2\| \end{aligned}$$

*1번 과정에서 $u_2 = v_2$ 로 시작을 해도 가능하지만, 반드시 v_1 과 v_2 를 사용해야 합니다. 아무런 벡터를 잡고 Gram-Schmidt를 진행할 수는 없으며 u 는 v 벡터들을 생성하는 직교 기저이어야만 $v - \text{proj}_u(v)$ 값이 v 공간에 속할 수 있기 때문입니다
(부분 공간에 포함).

Gram-Schmidt 방법

3D example



v_1, v_2, v_3 의 벡터가 있을 때 Gram-Schmidt 과정을 적용해보겠습니다.


Gram-Schmidt 방법

아래 그림과 같이 v_2 와 정사영된 벡터를 빼줌으로써 u_2 를 찾을 수 있습니다.

1. 먼저 임의의 벡터 u_1 을

$$u_2 = v_2 - \text{proj}_{u_1} v_2 = v_2 - \frac{v_2 \cdot u_1}{u_1 \cdot u_1} u_1$$

2. u_2 를 찾기 위해서 2차원 공간을 만들고
찾고





$$u_2 = v_2 - \text{proj}_{u_1} v_2 = v_2 - \frac{v_2 \cdot u_1}{u_1 \cdot u_1} u_1$$


Gram-Schmidt 방법

계산된 2개의 정사영 벡터의 합 (빨간색)은 아래 그림과 같이 v_3 를 u_1, u_2 평면에 정사영한 벡터가 됩니다.

3. u_3 를 찾기 위해서 위의 과정에서 구한 u_1 과 u_2 벡터에 v_3 를 정사영을 하여 $proj_{u_2}(v_3)$ 와 $proj_{u_1}(v_3)$ 를 구합니다.



u_3 를 구하기 위해서 v_3 에 정사영 벡터 합을 빼줌으로서 u_3 를 얻을 수 있습니다.



$$u_3 = v_3 - proj_{u_1} v_3 - proj_{u_2} v_3 = v_3 - \frac{v_3 \cdot u_1}{u_1 \cdot u_1} u_1 - \frac{v_3 \cdot u_2}{u_2 \cdot u_2} u_2$$

Gram-Schmidt 방법

4. 마지막으로 정규화 과정을 수행하면 정규 직교 기저를 얻을 수 있습니다.

$$e_1 = \frac{u_1}{\|u_1\|}$$
$$e_2 = \frac{u_2}{\|u_2\|}$$
$$e_3 = \frac{u_3}{\|u_3\|}$$

Gram-Schmidt 방법

Generalization

일반화된 과정은 아래의 사진과 같습니다. 1번에서 basis가 주어졌을 때 2번 과정을 통해서 직교 벡터들 (w)를 구했으며, 3번에서 정규화하여 orthonormal basis를 얻어낼 수 있었습니다.

THEOREM 5.12 Gram-Schmidt Orthonormalization Process

1. Let $B = \{v_1, v_2, \dots, v_n\}$ be a basis for an inner product space V .
2. Let $B' = \{w_1, w_2, \dots, w_n\}$, where

$$w_1 = v_1$$

$$w_2 = v_2 - \frac{\langle v_2, w_1 \rangle}{\langle w_1, w_1 \rangle} w_1$$

$$w_3 = v_3 - \frac{\langle v_3, w_1 \rangle}{\langle w_1, w_1 \rangle} w_1 - \frac{\langle v_3, w_2 \rangle}{\langle w_2, w_2 \rangle} w_2$$

$$\vdots$$

$$w_n = v_n - \frac{\langle v_n, w_1 \rangle}{\langle w_1, w_1 \rangle} w_1 - \frac{\langle v_n, w_2 \rangle}{\langle w_2, w_2 \rangle} w_2 - \dots - \frac{\langle v_n, w_{n-1} \rangle}{\langle w_{n-1}, w_{n-1} \rangle} w_{n-1}.$$

Then B' is an *orthogonal* basis for V .

3. Let $u_i = \frac{w_i}{\|w_i\|}$. Then $B'' = \{u_1, u_2, \dots, u_n\}$ is an *orthonormal* basis for V .
Also, $\text{span}\{v_1, v_2, \dots, v_k\} = \text{span}\{u_1, u_2, \dots, u_k\}$ for $k = 1, 2, \dots, n$.




QR 분해법

QR 분해법

Definition

QR 분해는 실수 행렬을 직교 행렬 (Q, Normal orthogonal matrix)과 상삼각 행렬 (R, upper triangular matrix)의 곱으로 나타내는 행렬 분해 방법입니다.



[1] Overview of QR Decomposition

QR 분해법

Why

$Ax = b$ 문제는 상당히 실생활에 많이 존재합니다. b 라는 결과를 얻기 위해서 시스템 A 에 어떠한 x 인풋을 넣어야 얻을 것 인지에 생각할 때 분야를 막론하고 다양한 예제들이 존재할 것입니다.

$$Ax = b$$

$Ax = b$ 를 만족하는 x 를 구하고 싶다고 가정할 때 일반적인 방법은 $x = A^{-1}b$ 또는 pseudo inverse와 같이 A 의 역행렬을 계산하여 b 에 곱하고 x 를 얻을 수가 있습니다.

$$x = A^{-1}b \quad or \quad x = A^+b$$

하지만 역행렬을 구하는 것이 전공책에 제시된 문제 수준에서 더 나아가 차원이 커질수록 시간의 복잡도가 기하급수적으로 커지게 됩니다. 때문에 우리는 역행렬을 직접 구하지 않고 시간 복잡도가 선형이며, 수치적으로 용이한 LU 분해 또는 QR 분해를 사용합니다.

QR 분해법

(1) Characteristics of `Q` (Q 행렬 특성)

QR 분해에서 Q는 Gram-Schmidt Process를 통해서 얻어진 정규 직교 기저로 이뤄진 행렬입니다.

$$Q = [q_1 \quad q_2 \quad \cdots \quad q_n]$$

Q는 직교 행렬이기 때문에 symmetric matrix이면서 다음의 성질을 가지고 있습니다.

$$(1) Q^T Q = \begin{pmatrix} 1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1 \end{pmatrix}, \quad i.e. Q^T Q = Q Q^T = I \quad \therefore Q^{-1} = Q^T$$

$$(2) \|Q\underline{x}\| = \|\underline{x}\| \text{ for } \forall \underline{x}, \quad \langle Q\underline{x}, Q\underline{y} \rangle = \langle \underline{x}, \underline{y} \rangle \text{ for } \underline{x}, \underline{y}$$

QR 분해법

(2) Characteristics of `R` (R 행렬 특성)

R은 상삼각 행렬입니다. 행렬의 주대 각선을 기준으로 대각 항의 모든 아래쪽 원소 값이 0인 행렬이 **상 삼각 행렬**입니다.

$$\begin{bmatrix} u_{1,1} & u_{1,2} & u_{1,3} & \dots & u_{1,n} \\ & u_{2,2} & u_{2,3} & \dots & u_{2,n} \\ & & \ddots & \ddots & \vdots \\ & & & \ddots & u_{n-1,n} \\ 0 & & & & u_{n,n} \end{bmatrix}$$

상삼각 행렬은 덧셈, 곱셈, 역행렬에 대해 닫혀있습니다. 때문에 삼삼각 행렬끼리의 덧셈, 곱셈, 역행렬 연산을 통해 나오는 행렬 (또는 결과) 또한 상삼각 행렬 형태를 지닙니다 (마찬가지로 하 삼각 행렬 또한 동일합니다).

*다만 순 삼각 행렬은 주 대각선 성분들이 0 값을 가지기에 역행렬에 대해 닫혀있기 위해서는 삼각 행렬이 가역 행렬 이어야 하는 추가 조건이 반드시 존재해야 합니다.

QR 분해법

이러한 성질을 통해서 결과적으로 $Ax=b$ 문제는 다음과 같이 풀이될 수 있습니다. $A=QR$ 일 때 아래의 순서와 동일하게 진행을 하면 x 를 도출할 수 있습니다.

$$A = QR$$

$$(1) R^T Q^T Q R x = R^T Q^T b$$

$$(2) R^T R x = R^T Q^T b$$

$$(3) (R^T)^{-1} R^T R x = (R^T)^{-1} R^T Q^T b$$

$$(4) R x = Q^T b$$

(5) if $y = Rx = Q^T b$ we can obtain y
and can solve $Rx = y$ with back substitution

QR 분해법

QR Decomposition advantages (QR 분해 장점들)

- (1) QR 분해는 A 가 정방 행렬이 아닐 때 (행과 열 개수가 다른 행렬)도 적용이 가능합니다.
- (2) 컴퓨터에 알고리즘을 적용 시 구현이 용이합니다.

QR 분해법

다음 과정은 R 행렬을 얻는 과정입니다.

$A = QR$ 일 때, 열 벡터 a_n 을 가진 행렬 A 는 다음과 같습니다.

$$A = [a_1 \ a_2 \ a_3 \ \cdots \ a_n]$$

선형 독립인 열 벡터 a_n 으로 구성된 A 에 Gram-Schmidt과정을 적용하면 다음과 같이 Q 행렬을 얻습니다.

$$Q = [q_1 \ q_2 \ \cdots \ q_n]$$

이때 Q 행렬의 q_n 열 벡터는 A 에 대해서 정규 직교 기저이기 때문에 a_n 을 q_n 의 선형 결합으로 표현 가능합니다.

$$\begin{aligned} \mathbf{a}_1 &= (\mathbf{a}_1^T \mathbf{q}_1) \mathbf{q}_1 \\ \mathbf{a}_2 &= (\mathbf{a}_2^T \mathbf{q}_1) \mathbf{q}_1 + (\mathbf{a}_2^T \mathbf{q}_2) \mathbf{q}_2 \\ &\vdots \\ \mathbf{a}_n &= \sum_{i=1}^n (\mathbf{a}_n^T \mathbf{q}_i) \mathbf{q}_i \end{aligned}$$

QR 분해법

정리하면 $A = QR$ 형태는 아래와 같습니다.

$$\begin{bmatrix} | & | & \cdots & | \\ a_1 & a_2 & \cdots & a_n \\ | & | & \cdots & | \end{bmatrix} = \begin{bmatrix} | & | & \cdots & | \\ q_1 & q_2 & \cdots & q_n \\ | & | & \cdots & | \end{bmatrix} \begin{bmatrix} a_1 \cdot q_1 & a_2 \cdot q_1 & \cdots & a_n \cdot q_1 \\ a_1 \cdot q_2 & a_2 \cdot q_2 & \cdots & a_n \cdot q_2 \\ \vdots & \vdots & \ddots & \vdots \\ a_1 \cdot q_n & a_2 \cdot q_n & \cdots & a_n \cdot q_n \end{bmatrix}$$

이때 $a_1 \cdot q_2$ 을 생각해볼 때 q_2 는 a_1 및 q_1 성분이 모두 제거된 성분이기때 값이 0이 됩니다.

QR 분해법

마찬가지로 $a_i \cdot q_j$ 에 대해 생각할 때 $i < j$ 인 경우 $a_i \cdot q_j = 0$ 이 되어버리기 때문에 아래와 같은 식으로 변경되어서 R행렬이 곧 상 삼각 행렬로 됩니다.

$$[a_1 \ a_2 \ \cdots \ a_n] = [q_1 \ q_2 \ \cdots \ q_n] \begin{bmatrix} a_1^T q_1 & a_2^T q_1 & \cdots & a_n^T q_1 \\ 0 & a_2^T q_2 & \cdots & a_n^T q_2 \\ 0 & 0 & \cdots & a_n^T q_3 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_n^T q_n \end{bmatrix}$$

정리하면 R 행렬은 a와 q로 이뤄진 행렬이며 a와 q정보는 이미 다 알고 있으므로 R을 도출해낼 수가 있습니다.

QR 분해법

Example

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$$

A가 위와 같은 행렬일 때 QR 분해를 해보겠습니다. 순서는 다음과 같습니다.

(1) Gram-Schmidt 과정을 통해 Q 행렬 계산

(2) Q 행렬과 A 행렬 연산을 통해 R 행렬 계산

QR 분해법

먼저 (1) Gram-Schmidt 과정을 수행하기 위해서 행렬 A의 열 벡터를 다음과 같이 정의합니다.

$$a_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, a_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, a_3 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}$$

직교 벡터인 u_1, u_2, u_3 에 대해서 계산을 위해서 먼저 하나의 a_n 벡터를 u_n 벡터와 동일하게 정합니다.

$$a_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} = u_1$$

u_2 벡터를 구하기 위해서 u_1 에 a_2 벡터를 정사영하여서 계산합니다.

$$u_2 = a_2 - \text{proj}_{u_1} a_2 = a_2 - \frac{u_1 \cdot a_2}{u_1 \cdot u_1} u_1 = \left(\frac{1}{2}, -\frac{1}{2}, 1\right)$$

QR 분해법

u_3 벡터를 구하기 위해서 u_1 과 u_2 에 먼저 정사영을 각각 하여 정 사영된 벡터를 각각 구하고, u_3 에 정사영된 벡터들을 빼줍니다.

$$u_3 = a_3 - \text{proj}_{u_1} a_3 - \text{proj}_{u_2} a_3 = a_3 - \frac{u_1 \cdot a_3}{u_1 \cdot u_1} u_1 - \frac{u_2 \cdot a_3}{u_2 \cdot u_2} u_2 = \left(-\frac{2}{3}, \frac{2}{3}, \frac{2}{3}\right)$$

마지막으로 정규화를 합니다.

$$\begin{aligned} e_1 &= \frac{u_1}{\|u_1\|} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}, 0\right) \\ e_2 &= \frac{u_2}{\|u_2\|} = \left(\frac{1}{\sqrt{6}}, -\frac{1}{\sqrt{6}}, \frac{2}{\sqrt{6}}\right) \\ e_3 &= \frac{u_3}{\|u_3\|} = \left(-\frac{1}{\sqrt{3}}, \frac{1}{\sqrt{3}}, \frac{1}{\sqrt{3}}\right) \end{aligned}$$

QR 분해법


(2) 과정인 R 행렬을 계산하면 최종적으로 아래와 같이 A 행렬을 구할 수 있습니다.

$$A = QR = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{6} & -1/\sqrt{3} \\ 1/\sqrt{2} & -1/\sqrt{6} & 1/\sqrt{3} \\ 0 & 2/\sqrt{6} & 1/\sqrt{3} \end{bmatrix} \begin{bmatrix} 2/\sqrt{2} & 1/\sqrt{2} & 1/\sqrt{2} \\ 0 & 3/\sqrt{6} & 1/\sqrt{6} \\ 0 & 0 & 2/\sqrt{3} \end{bmatrix}$$



•
•
•
•
•
•
•
•
•

고유값 과 고유벡터 고유분해 (eigen – decomposition)


행렬-벡터 곱셈




$$A = \begin{pmatrix} 3 & 1 \\ 2 & 0 \end{pmatrix}$$



$$B = \begin{pmatrix} 1 & 2 \\ 0 & 2 \end{pmatrix}$$



행렬-벡터 곱셈



- 어떤 벡터들은 벡터의 크기만 변화 시키기도 한다.


고유값 & 고유벡터

고유치(값) - 고유벡터

벡터 x 에 대해 $Ax = \lambda x$ 를 만족시키는 값 λ

x : A 의 고유벡터

λ : A 의 고유값(치)



고유치(값) - 고유벡터

- 고유벡터 λ 는 다음 조건 $Ax = \lambda x$ 를 만족시킨다.

$$Ax = \lambda x$$

$$\Rightarrow Ax - \lambda x = (A - \lambda I)x = 0$$

$$\Rightarrow \underline{\det(A - \lambda I) = 0}$$

 A 의 특성 다항식

예제)

$$A = \begin{pmatrix} 2 & 2 \\ 0 & 3 \end{pmatrix} \Rightarrow \det(A - \lambda I) = \det \begin{pmatrix} 2 - \lambda & 2 \\ 0 & 3 - \lambda \end{pmatrix} \\ = (2 - \lambda)(3 - \lambda)$$

그러므로, $\lambda = 2, 3$

고유치(값) - 고유벡터

- 고유벡터 x 는 각 고유값 λ 에 대해 $Ax = \lambda x$ 를 만족한다.
- 하나의 고유값 $\lambda = 2$ 에 대한 고유벡터를 찾아라

$$A = \begin{pmatrix} 2 & 2 \\ 0 & 3 \end{pmatrix} \Rightarrow \text{하나의 고유값 } \lambda = 2 \text{ 라 하자}$$

$$\Rightarrow \begin{pmatrix} 2-2 & 2 \\ 0 & 3-2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 & 2 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\Rightarrow \begin{cases} 0 \times x_1 + 2 \times x_2 = 0 \\ 0 \times x_1 + 1 \times x_2 = 0 \end{cases} \Rightarrow x_1 : \text{임의의 값}, x_2 = 0$$

$$\Rightarrow x = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad (\text{여기서 } x_1 = 1 \text{ (기본 값)을 택한다.})$$

고유치(값) - 고유벡터

- 고유벡터 x 는 고유값 λ 에 대해 $Ax = \lambda x$ 를 만족한다.
- 하나의 고유값 $\lambda = 3$ 에 대한 고유벡터를 찾아라

$$A = \begin{pmatrix} 2 & 2 \\ 0 & 3 \end{pmatrix} \Rightarrow \text{고유값 } \lambda = 3 \text{ 이라고 하자}$$

$$\Rightarrow \begin{pmatrix} 2-3 & 2 \\ 0 & 3-3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} -1 & 2 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\Rightarrow \begin{cases} -1 \times x_1 + 2 \times x_2 = 0 \\ 0 \times x_1 + 0 \times x_2 = 0 \end{cases} \Rightarrow x_2 : \text{임의의값}, x_1 = 2$$

$$\Rightarrow x = \begin{pmatrix} 2 \\ 1 \end{pmatrix} \quad (x_2 = 1 \text{ 값을 택한다.})$$

고유치(값) - 고유벡터

$$\begin{aligned}\text{예제 2) } B = \begin{pmatrix} 4 & 2 \\ -1 & 1 \end{pmatrix} &\Rightarrow \det(B - \lambda I) = \det \begin{pmatrix} 4 - \lambda & 2 \\ -1 & 1 - \lambda \end{pmatrix} \\ &= (4 - \lambda)(1 - \lambda) + 2 \\ &= \lambda^2 - 5\lambda + 6 \\ &= (\lambda - 2)(\lambda - 3) = 0\end{aligned}$$

그러므로, $\lambda = 2, 3$

\Rightarrow 고유값 $\lambda = 3$ 에 대해

$$\begin{aligned}&\Rightarrow \begin{pmatrix} 4 - 3 & 2 \\ -1 & 1 - 3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 1 & 2 \\ -1 & -2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ &\Rightarrow \begin{cases} 1 \times x_1 + 2 \times x_2 = 0 \\ -1 \times x_1 - 2 \times x_2 = 0 \end{cases} \Rightarrow x_1 = 2 \text{ 를 택하면 } x_2 = -1 \\ &\Rightarrow x = \begin{pmatrix} 2 \\ -1 \end{pmatrix}\end{aligned}$$

고유값 $\lambda = 2$ 에 대해서도 위와 같은 방법으로 진행하면 고유벡터를 얻을 수 있다.
따라서

$$x = \begin{pmatrix} -1 \\ 1 \end{pmatrix} \quad (x_2 = 1)$$

고유치(값) - 고유벡터

⇒ 고유치가 / 중근인 경우 $(\lambda_1 = \lambda_2 = \dots = \lambda_l \neq \dots \neq \lambda_n)$

행렬 A 의 고유치가 중근이면, 앞의 방법으로는 n 개의 선형 독립인 고유벡터를 구할 수 없으며 대각화도 할 수 없다. 그러나 고유치가 l 중근인 경우, 즉 $\lambda_1 = \lambda_2 = \dots = \lambda_l$ 이면, 대각행렬과 유사한 다음과 같은 방법으로 표현할 수 있다.

$$\Lambda = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & \cdot & \cdot & \cdot & 0 \\ 0 & \lambda_2 & 1 & 0 & 0 & \cdot & \cdot & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ 0 & 0 & \cdot & \cdot & \lambda_{l-1} & 1 & \cdot & 0 \\ 0 & 0 & 0 & \cdot & 0 & \lambda_l & \cdot & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ 0 & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \lambda_n \end{bmatrix} \quad (2.81)$$

한편, 고유치가 l 중근인 경우, $\lambda_1 = \lambda_2 = \dots = \lambda_l$ 에 대한 고유벡터는 단근인 경우의 식 (2.79)와 같이

$$AX_1 = \lambda_1 X_1 \quad (2.82)$$

로부터 X_1 을 먼저 구한 다음,

고유치(값) - 고유벡터

⇒ 고유치가 / 중근인 경우

$$(\lambda_1 = \lambda_2 = \dots = \lambda_l \neq \dots \neq \lambda_n)$$

$$AX_2 = X_1 + \lambda_1 X_2$$

$$AX_3 = X_2 + \lambda_1 X_3$$

⋮

⋮

$$AX_l = X_{l-1} + \lambda_1 X_l$$

(2.83)

또는

$$(A - \lambda_1 I)X_2 = X_1$$

$$(A - \lambda_1 I)X_3 = X_2$$

⋮


⋮

$$(A - \lambda_1 I)X_l = X_{l-1}$$


(2.84)

에서 차례대로 구한다. 나머지 $(n-l)$ 개의 고유치는 단일 고유치를 구하는 방법과 같다.

그래프에서의 행렬 곱셈




$$A = \begin{pmatrix} 2 & 2 \\ 0 & 3 \end{pmatrix}$$




고유치,
고유벡터

$$x = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$\lambda = 3, 2$$



$$B = \begin{pmatrix} 4 & 2 \\ -1 & 1 \end{pmatrix}$$



고유치,
고유벡터

$$x = \begin{pmatrix} 2 \\ -1 \end{pmatrix}, \begin{pmatrix} -1 \\ 1 \end{pmatrix}$$

$$\lambda = 3, 2$$

고유-분해 (eigen – decomposition)

$\lambda_1, \lambda_2, \dots, \lambda_n$ 이 $n \times n$ 정방행렬 A , 의 고유값이라면

x_1, x_2, \dots, x_n 는 각 고유값 $\lambda_1, \lambda_2, \dots, \lambda_n$ 에 대응하는 고유벡터이다

$$P = (x_1 \ x_2 \ \dots \ x_n) \text{ 이고 } \Sigma = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{pmatrix},$$

그때 $AP = P \Sigma$, 그리하여 $A = P \Sigma P^{-1}$.

즉. 고유벡터 행렬 P 는 행렬 A 를 이용하여 대각행렬 Σ 를 만들 수 있다.

$$P^{-1}AP = \Sigma$$

고유-분해 (eigen – decomposition)

$$A = P \Sigma P^{-1}$$

예제)

행렬	고유값 고유벡터	고유-분해
$A = \begin{pmatrix} 2 & 2 \\ 0 & 3 \end{pmatrix}$	$x = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ $\lambda = 3, 2$	$\begin{pmatrix} 2 & 2 \\ 0 & 3 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 1 & 0 \end{pmatrix}^{-1}$
$B = \begin{pmatrix} 4 & 2 \\ -1 & 1 \end{pmatrix}$	$x = \begin{pmatrix} 2 \\ -1 \end{pmatrix}, \begin{pmatrix} -1 \\ 1 \end{pmatrix}$ $\lambda = 3, 2$	$\begin{pmatrix} 4 & 2 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix}^{-1}$

고유-분해 (eigen – decomposition)

$$A = P \Sigma P^{-1}$$

고유벡터 x_1, x_2, \dots, x_n 에 대해

$$P e_i = x_i, \quad P^{-1} x_i = e_i,$$


단위벡터

예제)

$$\begin{aligned} A = \begin{pmatrix} 2 & 2 \\ 0 & 3 \end{pmatrix} \quad x = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad \text{\textit{A의 고유벡터}} \quad \Rightarrow \begin{pmatrix} 2 & 1 \\ 1 & 0 \end{pmatrix}^{-1} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 1 & -2 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \\ \Rightarrow \begin{pmatrix} 2 & 1 \\ 1 & 0 \end{pmatrix}^{-1} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 1 & -2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \end{aligned}$$

그래프 상에서의 고유-분해의 의미

$$A = P \Sigma P^{-1}$$



고유-분해의 의미

- $P = (x_1 \ x_2 \ \cdots \ x_n), \Sigma = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix}, P^{-1} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$ 일 때

행렬 $A = P \Sigma P^{-1},$

따라서 $P \Sigma P^{-1} = \lambda_1 x_1 y_1 + \lambda_2 x_2 y_2 + \cdots + \lambda_n x_n y_n$

따라서 고유-분해는 때때로 스펙트럼분해(
the spectral decomposition.) 라고도 불린다.

예제)

$$\begin{aligned} A = \begin{pmatrix} 2 & 2 \\ 0 & 3 \end{pmatrix} &= \begin{pmatrix} 2 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & -2 \end{pmatrix} = 3 \begin{pmatrix} 2 \\ 1 \end{pmatrix} \begin{pmatrix} 0 & 1 \end{pmatrix} + 2 \begin{pmatrix} 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & -2 \end{pmatrix} \\ &= 3 \begin{pmatrix} 0 & 2 \\ 0 & 1 \end{pmatrix} + 2 \begin{pmatrix} 1 & -2 \\ 0 & 0 \end{pmatrix} \end{aligned}$$

고유-분해의 대수적 의미

$|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|$ 일때


$$A = \lambda_1 x_1 y_1 + \lambda_2 x_2 y_2 + \dots + \lambda_{n-1} x_{n-1} y_{n-1} + \lambda_n x_n y_n$$

중요 \longleftrightarrow 특징들 \longleftrightarrow 무시

- A 를 분석하기 위해 중요한 특징만 사용한다 \longrightarrow 특징추출(Feature extraction)
- 무시가능 특징들을 버릴 수 있다. \longrightarrow 잡음제거(Denoising)

고유-분해 과정

고유-분해의 과정



고유벡터를 찾기 위해, 특성 다항식의 해를 구해야한다.

그러나 3차 이상의 다항식을 푸는 것은 불가능하다