



인공지능수학

(선형대수학)



개요

벡터, 행렬

특징

노름, 거리, 차원,
내적, 행렬식

연산

벡터합, 스칼라곱,
행렬합, 행렬곱

특수형태

영행렬, 음행렬, 단위행렬,
역행렬, 대각행렬,
전치행렬 등

선형문제

선형결합

기본행변환

가우스-조르단 소거법

알고리즘

LU분해

QR분해

최소제곱법

그람-슈미트 방법

행렬의 특성값

고윳값&고유벡터

특잇값

특잇값분해
(SVD)

고유치와 고유벡터

⇒ 고유치가 단근인 경우

$$(\lambda_1 \neq \lambda_2 \neq \dots \neq \lambda_n)$$

행렬 A 의 i 번째 고유치 λ_i 에 대해, 다음을 만족하는 영이 아닌 벡터 $n \times 1$ 차원의 X_i 를 행렬 A 의 고유벡터라고 한다.

$$AX_i = \lambda_i X_i \quad (2.79)$$

그런데 이 식이 임의의 스칼라 상수 k 에서도 다음 방정식을 만족한다.

$$A(kX_i) = \lambda_i (kX_i) \quad (2.80)$$

이 경우 해 벡터는 kX_i 가 되므로, 고유벡터는 일의적(unique)이 아닌 임의의 길이가 설정된다.

고유치와 고유벡터

⇒ 고유치가 / 중근인 경우

$$(\lambda_1 = \lambda_2 = \dots = \lambda_l \neq \dots \neq \lambda_n)$$

행렬 \mathbf{A} 의 고유치가 중근이면, 앞의 방법으로는 n 개의 선형 독립인 고유벡터를 구할 수 없으며 대각화도 할 수 없다. 그러나 고유치가 l 중근인 경우, 즉 $\lambda_1 = \lambda_2 = \dots = \lambda_l$ 이면, 대각행렬과 유사한 다음과 같은 방법으로 표현할 수 있다.

$$\Lambda = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & \cdot & \cdot & \cdot & 0 \\ 0 & \lambda_2 & 1 & 0 & 0 & \cdot & \cdot & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ 0 & 0 & \cdot & \cdot & \lambda_{l-1} & 1 & \cdot & 0 \\ 0 & 0 & 0 & \cdot & 0 & \lambda_l & \cdot & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ 0 & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \lambda_n \end{bmatrix} \quad (2.81)$$

한편, 고유치가 l 중근인 경우, $\lambda_1 = \lambda_2 = \dots = \lambda_l$ 에 대한 고유벡터는 단근인 경우의 식 (2.79)와 같이

$$\mathbf{A}\mathbf{X}_1 = \lambda_1 \mathbf{X}_1 \quad (2.82)$$

로부터 \mathbf{X}_1 을 먼저 구한 다음,

고유치와 고유벡터

⇒ 고유치가 / 중근인 경우

$$(\lambda_1 = \lambda_2 = \dots = \lambda_l \neq \dots \neq \lambda_n)$$

$$\begin{aligned} AX_2 &= X_1 + \lambda_1 X_2 \\ AX_3 &= X_2 + \lambda_1 X_3 \\ &\vdots \\ AX_l &= X_{l-1} + \lambda_1 X_l \end{aligned} \tag{2.83}$$

또는

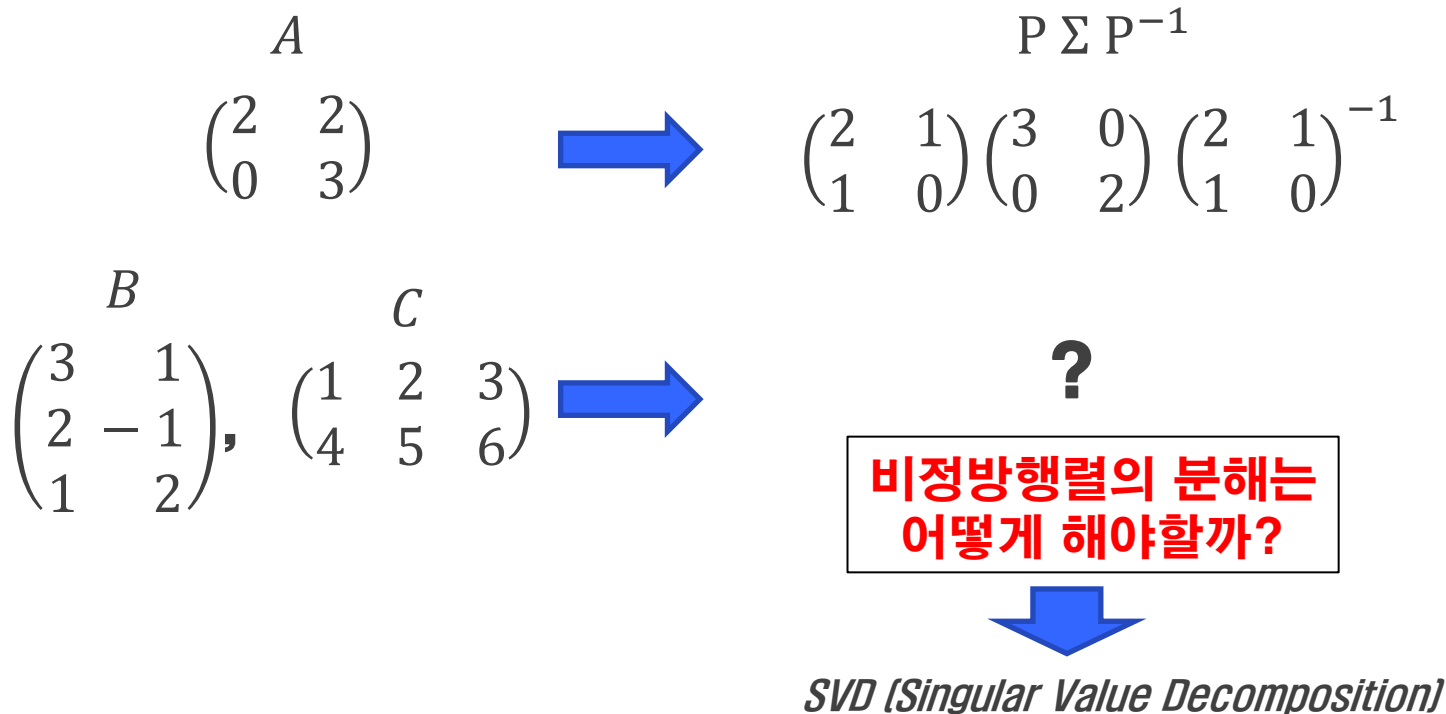
$$\begin{aligned} (A - \lambda_1 I)X_2 &= X_1 \\ (A - \lambda_1 I)X_3 &= X_2 \\ &\vdots \\ (A - \lambda_1 I)X_l &= X_{l-1} \end{aligned} \tag{2.84}$$

에서 차례대로 구한다. 나머지 $(n-l)$ 개의 고유치는 단일 고유치를 구하는 방법과 같다.

고윳값 분해

고윳값 분해의 문제

- 고윳값 분해는 오로지 정방행렬에 대해서만 가능하다.
- 하지만 정방행렬이 아닌 일반적인 행렬에 대해서도 고윳값을 이용한 분석을 하고싶다면, 어떻게 해야할까?



특잇값&특이벡터

■ 특잇값 & 특이벡터

행렬 $A(m \times n)$ 에 대해 $A^T A$ 를 하면 정방행렬 $n \times n$ 이 된다.
따라서 벡터 x , 스칼라 λ 가 다음 식 $(A^T A)x = \lambda x$ 을 만족한다면,

x : A 의 특이벡터 ----- 고유벡터
 $+\sqrt{\lambda} = \sigma$: A 의 x 에 대한 특잇값 -- 고유값

■ 특징

$A = [x_1 \ x_2 \ \cdots \ x_n]$ 가 $m \times n$ 행렬이고 x_1, x_2, \cdots, x_n 이 일차독립이면,

$A^T A$ 와 AA^T 의 0을 제외한 고윳값(특잇값)은 동일하다.

>> 이에 따라 이후 A 를 $m \geq n$ 인 $m \times n$ 행렬로 가정한다.

특이치 분해

특이치 행렬 S 는 AA' 또는 $A'A$ 의 고유치의 제곱근이 대각에 있는 대칭행렬이다. 여기서 U 의 열벡터는 AA' 행렬의 고유벡터이며, 각 열벡터는 행렬 A 의 좌측 특이벡터다. 이와 유사하게 V 의 열벡터는 $A'A$ 행렬의 고유벡터이며, 각 열벡터는 행렬 A 의 우측 특이벡터다.

- A 가 다음처럼 세 행렬의 곱으로 표현됩니다.

$$A = USV^T$$

$$\begin{aligned} A'A &= VS'U'USV' = V(S'S)V' \\ AA' &= USV'VS'U' = U(SS')U' \end{aligned}$$

- A 가 $m \times n$ 행렬일때

→ U 는 $m \times m$ 행렬 : U 는 AA' 의 고유벡터행렬

→ V 는 $n \times n$ 행렬 : V 는 $A'A$ 의 고유벡터행렬

→ S 는 $m \times n$ 행렬 : 특이치 대각 행렬

S 의 주대각 성분을 행렬 A 의 특잇값(singular value)이라고 부르며,

AA' 과 $A'A$ 의 고유값의 제곱근이다.

특이치 분해 – 경우의 수에 따른 방법

◆ (1) 행렬 A 의 퇴화로 랭크가 부족한 경우

경우 1 방정식의 수와 미지수의 수가 같은 경우

다음 행렬 A 는 정방행렬이지만, 대칭행렬은 아니다.

$$A = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix}$$

이 행렬에서 제1행과 제2행은 서로 종속이므로, $|A|=0$ 인 특이치가 있다. 이 경우, 원래의 행렬은 한 행이 퇴화했으므로 랭크는 1이 된다. 따라서 A^{-1} 은 존재하지 않는다.

그러나 특이치 분해를 이용하면, 고유치와 고유벡터는 내적과 외적 행렬에서 다음을 얻게 된다.

$$A^T A = \begin{bmatrix} 5 & 5 \\ 5 & 5 \end{bmatrix} \quad \text{및} \quad A A^T = \begin{bmatrix} 2 & 2 \\ 4 & 8 \end{bmatrix}$$

이것은 모두 대칭행렬이며, 고유치는 $\lambda_1 = 0$ 및 $\lambda_2 = 10$ 이다. 결국 행렬 A 의 특이치는 $\sigma_1 = 0$ 및 $\sigma_2 = \sqrt{10}$ 이 된다. 따라서 행렬 A 의 랭크는 1이며, 다음과 같이 특이치 분해로 풀 수 있다.

$$A = USV^T = \begin{bmatrix} 2/\sqrt{5} & 1/\sqrt{5} \\ -1/\sqrt{5} & 2/\sqrt{5} \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & \sqrt{10} \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}^T = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix}$$

특이치 분해 – 경우의 수에 따른 방법

경우 2 방정식의 수가 미지수의 수보다 적은 경우

다음 행렬 B 는 비정방행렬이며, 행렬의 랭크는 2이다.

$$B = \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix}$$

이 행렬에서 제1행과 제2행은 서로 종속이므로, $|B|=0$ 인 특이치가 있다. 이 경우, 원래의 행렬은 한 행이 퇴화했으므로 랭크는 1이 된다. 따라서 B^{-1} 은 존재하지 않는다.

그러나 특이치 분해를 이용하면, 고유치와 고유벡터는 내적과 외적 행렬에서 다음을 얻게 된다.

$$B^T B = \begin{bmatrix} 10 & 0 & 2 \\ 0 & 10 & 4 \\ 2 & 4 & 2 \end{bmatrix} \quad \text{및} \quad BB^T = \begin{bmatrix} 11 & 1 \\ 1 & 11 \end{bmatrix}$$

이것은 모두 대칭행렬이며, 전자의 고유치는 $\lambda_1 = 12$ 및 $\lambda_2 = 10$, $\lambda_3 = 0$ 이고, 후자의 고유치는 $\lambda_1 = 12$ 및 $\lambda_2 = 10$ 이다. 결국 행렬 B 의 특이치는 $\sigma_1 = \sqrt{12}$ 및 $\sigma_2 = \sqrt{10}$ 이 된다. 따라서 행렬 B 의 랭크는 2이며, 다음과 같이 특이치 분해로 풀 수 있다.

$$\begin{aligned} B &= USV^T \\ &= \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix} \begin{bmatrix} \sqrt{12} & 0 & 0 \\ 0 & \sqrt{10} & 0 \end{bmatrix} \begin{bmatrix} 1/\sqrt{6} & 2/\sqrt{5} & 1/\sqrt{30} \\ 2/\sqrt{6} & -1/\sqrt{5} & 2/\sqrt{30} \\ 1/\sqrt{6} & 0 & -5/\sqrt{30} \end{bmatrix} = \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix} \end{aligned}$$

특이치 분해 – 경우의 수에 따른 방법

경우 3 방정식의 수가 미지수의 수보다 많은 경우(랭크가 결여된 경우)

다음 행렬 C 는 비정방행렬이다.

$$C = \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{bmatrix}$$

이 행렬에서 제1행과 제2행은 서로 종속이며, 고유치와 고유벡터는 내적과 외적 행렬에서 다음을 얻게 된다.

$$C^T C = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix} \quad \text{및} \quad C C^T = \begin{bmatrix} 2 & 2 & 0 \\ 2 & 2 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

이것은 모두 대칭행렬이며, 전자의 고유치는 $\lambda_1 = 4$ 및 $\lambda_2 = 0$ 이고, 후자의 고유치는 $\lambda_1 = 4$ 및 $\lambda_2 = 0$, $\lambda_3 = 0$ 이다. 결국 행렬 C 의 특이치는 $\sigma_1 = \sqrt{4}$ 및 $\sigma_2 = 0$ 이 된다. 따라서 행렬 C 의 랭크는 1이며, 다음과 같이 특이치 분해로 풀 수 있다.

$$C = USV^T = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 1/\sqrt{2} & -1/\sqrt{2} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{4} & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix}^T = \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{bmatrix}$$

특이치 분해 – 경우의 수에 따른 방법

◆ (2) 랭크가 행렬 A 의 열 또는 행과 같아지는 경우

경우 4 랭크가 행렬 A 의 열 또는 행과 같아지는 경우

랭크가 행렬 A 의 열 또는 행과 같아지면, 의사 역행렬을 이용한다. 식 (2.54)의 미지수 벡터는 $m > n$ 일 때, 다음과 같이 좌 의사 역행렬 A_{LM}^{-1} 으로 구할 수 있으며,

$$\begin{aligned} A^T A x &= A^T b \\ x &= (A^T A)^{-1} A^T b = A_{LM}^{-1} b \end{aligned} \quad (2.55)$$

$n > m$ 일 때, 다음과 같이 우 의사 역행렬 A_{RM}^{-1} 으로 구할 수 있다.

$$\begin{aligned} A A^T x &= A^T b \\ x &= A^T (A A^T)^{-1} b = A_{RM}^{-1} b \end{aligned} \quad (2.56)$$

일반적으로 방정식의 수가 미지수의 수보다 많은 경우, 일종의 최소제곱법과 유사하게 좌 의사 역행렬로 다음을 구하고,

$$x = (A^T A)^{-1} A^T b = U \Lambda^{-1} V^T b \quad (2.57)$$

방정식의 수가 미지수의 수보다 적은 경우, 우 의사 역행렬로 다음을 구한다.

$$x = A^T (A A^T)^{-1} b = A_{RM}^{-1} b \quad (2.58)$$

특잇값 분해(SVD)

Singular Value Decomposition(SVD)

$$\begin{array}{ccccc} A & \xrightarrow{\text{SVD}} & U & \Sigma & V^T \\ \begin{bmatrix} \star & \star & \star \\ \star & \star & \star \\ \star & \star & \star \\ \star & \star & \star \end{bmatrix} & = & \begin{bmatrix} \blacksquare & \blacksquare & \blacksquare & \blacksquare \\ \blacksquare & \blacksquare & \blacksquare & \blacksquare \\ \blacksquare & \blacksquare & \blacksquare & \blacksquare \\ \blacksquare & \blacksquare & \blacksquare & \blacksquare \end{bmatrix} & \begin{bmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \\ 0 & 0 & \sigma_3 \\ 0 & 0 & 0 \end{bmatrix} & \begin{bmatrix} \blacklozenge & \blacklozenge & \blacklozenge \\ \blacklozenge & \blacklozenge & \blacklozenge \\ \blacklozenge & \blacklozenge & \blacklozenge \\ \blacklozenge & \blacklozenge & \blacklozenge \end{bmatrix} \end{array}$$

$A : m \times n$ 행렬

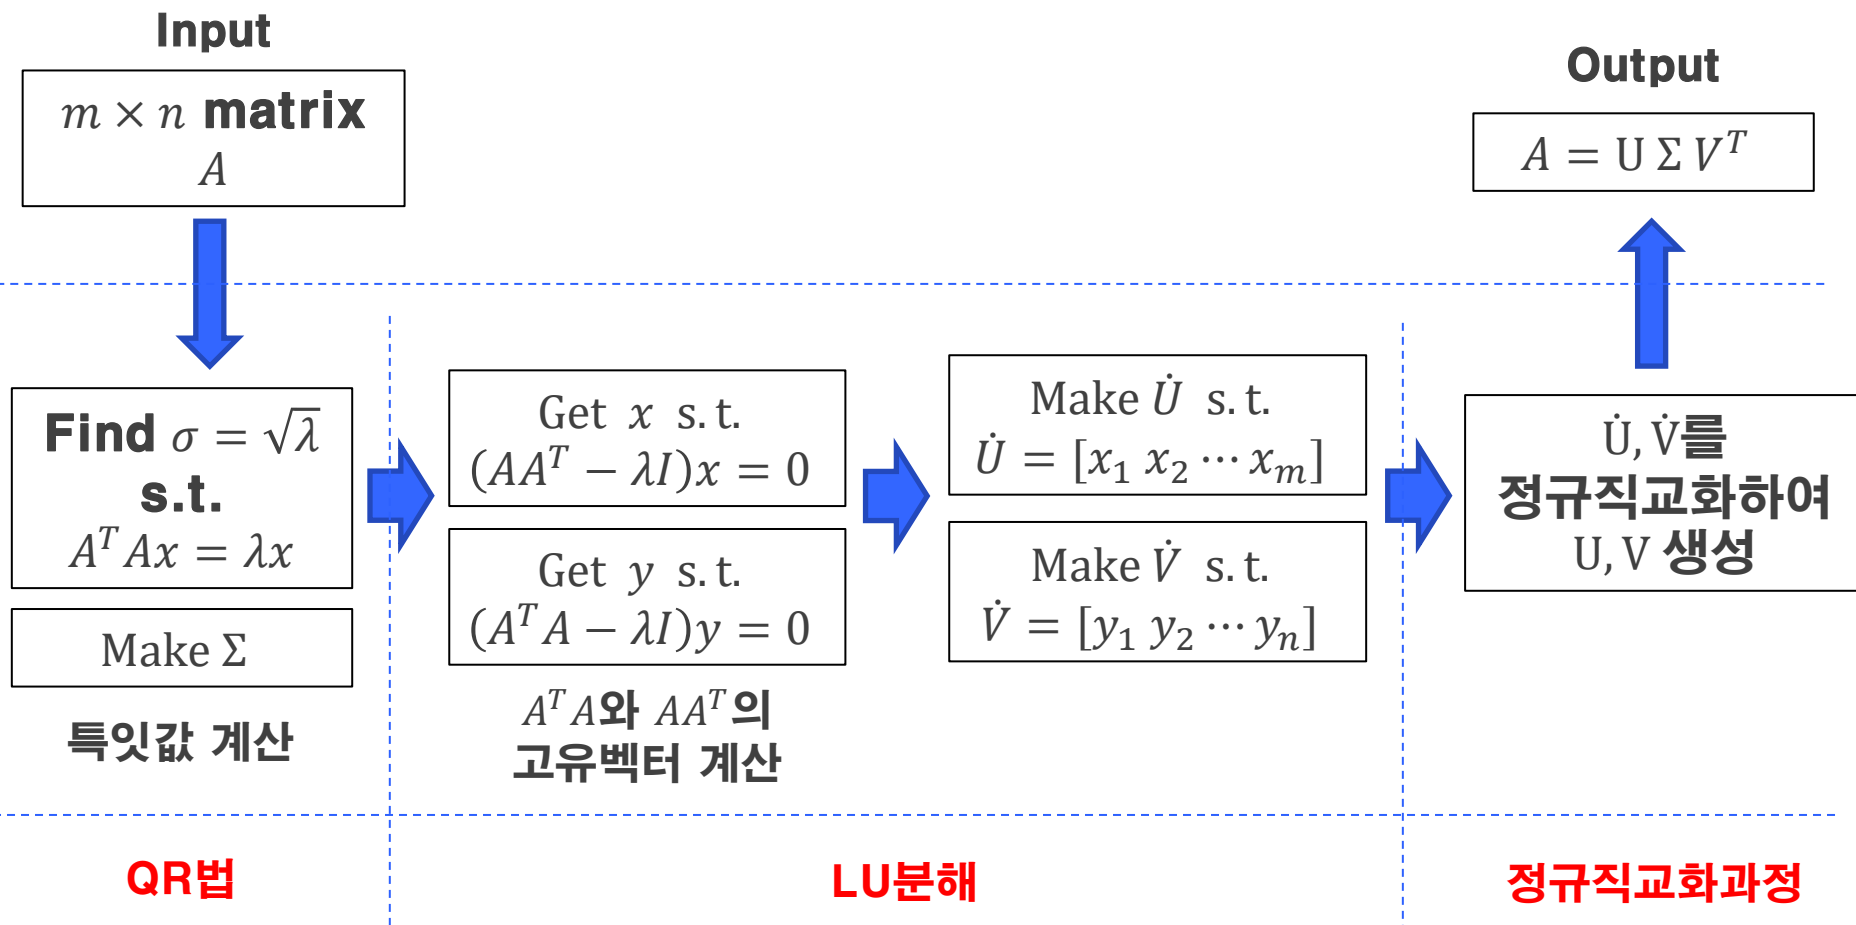
$\sigma_i : A$ 의 특잇값 ($\sigma_1 \geq \dots \geq \sigma_n$)

$U : AA^T = U(\Sigma\Sigma^T)U^T$ 를 만족하는 $m \times m$ 정규직교행렬

$V : A^TA = V(\Sigma^T\Sigma)V^T$ 를 만족하는 $n \times n$ 정규직교행렬


특잇값 분해(SVD)

SVD 계산과정



특잇값 분해(SVD)

고윳값 분해와 SVD 비교




SVD는 고윳값 분해를 일반화한 개념이라고 볼 수 있다.

특잇값 분해(SVD)

SVD의 기하학적 의미

만약 고윳값들이 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n$ 를 만족한다면,

$$A = \sigma_1 x_1 y_1 + \sigma_2 x_2 y_2 + \dots + \sigma_{n-1} x_{n-1} y_{n-1} + \sigma_n x_n y_n$$


중요함 특징의 중요도 무시해도 됨

위의 특징을 이용한 응용

- A 의 중요한 특징만 조사하고자 한다. > 특징 추출 (Feature extraction)
- 필요없는 특징들은 제거하고자 한다. > 디노이징 (Denoising)

고윳값 분해와 동일하다!

특잇값 분해(SVD)

Python을 이용한 SVD 계산

Simulation results

Input

```
>>> A
array([[1, 2],
       [2, 3],
       [3, 4],
       [4, 5]])
```

특잇값

U

V^T

$$A = U \Sigma V^T$$

The results of SVD

```
>>> u, s, vt = np.linalg.svd(A)
>>> u
array([[ -0.24054726,  -0.80133452,  -0.40008743,  -0.37407225],
       [ -0.3934325 ,  -0.38106544,   0.25463292,   0.79697056],
       [ -0.54631774,   0.03920365,   0.69099646,  -0.47172438],
       [ -0.69920298,   0.45947273,  -0.54554195,   0.04882607]])
>>> s
array([9.15211593, 0.48864503])
>>> vt
array([[ -0.59693053,  -0.80229293],
       [ 0.80229293,  -0.59693053]])
```

특잇값 분해(SVD)

Python을 이용한 SVD 계산

Simulation results

```
>>> A
array([[1, 2],
       [2, 3],
       [3, 4],
       [4, 5]])
```

$U \Sigma V^T$


Σ

검증


```
>>> S
array([[9.15211593, 0.],
       [0., 0.48864503],
       [0., 0.],
       [0., 0.]])
>>> B = np.matmul(np.matmul(u,S),vt)
>>> B
array([[1., 2.],
       [2., 3.],
       [3., 4.],
       [4., 5.]])
```

절단된 SVD


절단된 SVD



Full SVD




**Thin SVD
(square matrix)**



**Compact SVD
($\sigma_i = 0$ 인것 제거)**

*Thin SVD와 다르게
 $\sigma_i = 0$ 인 특잇값도 삭제한다.



Truncated SVD

$$A_k = \sigma_1 u_1 v^T + \dots + \sigma_k u_k v^T$$

* 유의미한 고윳값 σ_i 들을 제외하고 전부 삭제한다.

절단된 SVD

■ Eckart-Young theorem

$A_k = \sigma_1 u_1 v^T + \dots + \sigma_k u_k v^T$ 를 A 의 truncated matrix라 하자.

만약 B 가 rank k 인 행렬이라면, $|A - B| \geq |A - A_k|$ 가 항상 성립한다.



Truncated matrix A_k 는 A 와 가장 비슷한 rank k 행렬이다!!

이에 따라 Truncated SVD의 결과를 A 의 근사값으로 사용할 수 있다.

특잇값 분해(SVD)

SVD의 응용

무어-팬로즈 의사역행렬

$$A = U \Sigma V^T \\ \Rightarrow \underline{A^+} = V \Sigma^+ U^T$$

$$\Sigma^+ = \begin{bmatrix} \frac{1}{\sigma_1} & 0 & 0 \\ 0 & \frac{1}{\sigma_2} & 0 \\ 0 & 0 & \frac{1}{\sigma_3} \\ 0 & 0 & 0 \end{bmatrix}^T$$

만약 A 가 $m \times n$ 행렬이면,
 $AA^+ = I_m$.

데이터 압축
(절단 SVD의 r 의 값)

